.UBAfiuba
FACULTAD DE INGENIERÍA

Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación

Ing. Santiago Federico Bettig

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Ing. Leandro Javier Cymberknop (CIBIO, UTN FRBA)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de [lugar], [mes] de [año]

Resumen

En esta memoria se presenta el desarrollo de un sistema de clasificación automática de sonidos de auscultación cardíaca y pulmonar basado en redes neuronales profundas, concebido como herramienta de apoyo al diagnóstico para el médico generalista. El sistema procesa grabaciones obtenidas con estetoscopios digitales, las transforma en representaciones tiempo-frecuencia y detecta la presencia de hallazgos patológicos en ambos tipos de sonido. A diferencia de la mayoría de los trabajos previos, que tratan los sonidos cardíacos y pulmonares por separado, el trabajo aborda la auscultación cardiopulmonar de forma integrada y compara este enfoque con el de modelos independientes para cada órgano. El trabajo se realizó en colaboración con el Centro de Investigación y Desarrollo en Ingeniería Biomédica de la Universidad Tecnológica Nacional.

A lo largo de la memoria se describen las bases de datos públicas utilizadas, el preprocesamiento de las señales, el diseño y el entrenamiento de los modelos, y los ensayos realizados para evaluar su desempeño. En el desarrollo se aplicaron contenidos de la especialización vinculados con el análisis de datos, el aprendizaje automático, el aprendizaje profundo, las redes neuronales convolucionales y la gestión de proyectos.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. La auscultación cardiopulmonar . . . 1
1.2. Contexto y motivación . . . 2
1.3. Estado del arte . . . 3
1.4. Objetivos y alcance . . . 5

2. Introducción específica 7
2.1. Estilo y convenciones . . . 7
2.1.1. Uso de mayúscula inicial para los título de secciones . . . 7
2.1.2. Este es el título de una subsección . . . 7
2.1.3. Figuras . . . 8
2.1.4. Tablas . . . 9
2.1.5. Ecuaciones . . . 10

3. Diseño e implementación 11
3.1. Análisis del software . . . 11

4. Ensayos y resultados 13
4.1. Pruebas funcionales del hardware . . . 13

5. Conclusiones 15
5.1. Conclusiones generales . . . 15
5.2. Próximos pasos . . . 15

Bibliografía 17

Índice de figuras

1.1. Forma de onda y espectrograma en escala Mel de cuatro grabaciones de auscultación: sonido cardíaco normal, sonido cardíaco con soplo, sonido pulmonar normal y sonido pulmonar con crepitantes. 2

2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo. 8
2.2. Imagen tomada de la página oficial del procesador[1]. 9
2.3. ¿Por qué de pronto aparece esta figura? 9
2.4. Tres gráficos simples. 9

Índice de tablas

1.1. Comparación de trabajos representativos del estado del arte 4

2.1. caption corto 10

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presenta el área en la que se enmarca el trabajo, el contexto y la motivación que le dieron origen, una revisión del estado del arte en la clasificación automática de sonidos de auscultación y los objetivos y el alcance del proyecto.

1.1. La auscultación cardiopulmonar

La auscultación es la técnica de exploración clínica que consiste en escuchar los sonidos generados en el interior del cuerpo, principalmente los del corazón y los pulmones. Desde que René Laënnec inventó el estetoscopio en 1816 y lo utilizó para vincular los sonidos torácicos con los hallazgos de autopsia [1], la auscultación se convirtió en uno de los pilares del examen físico. Su vigencia se explica por tres características: es no invasiva, tiene un costo muy bajo y brinda información inmediata en el lugar de atención.

Los sonidos cardíacos normales se originan principalmente en el cierre de las válvulas y se perciben como dos golpes breves por ciclo, conocidos como primer y segundo ruido (S1 y S2). Distintas alteraciones modifican este patrón. Los soplos son sonidos producidos por el flujo turbulento de la sangre y se asocian, por ejemplo, a valvulopatías o a cardiopatías congénitas. También pueden aparecer ruidos adicionales, como el tercer y el cuarto ruido (S3 y S4), o irregularidades del ritmo. En el caso de los pulmones, el flujo de aire durante la respiración produce los ruidos respiratorios normales. Sobre ellos pueden superponerse sonidos adventicios, como los crepitantes, que son eventos discontinuos y de muy corta duración, y las sibilancias, que son sonidos continuos de carácter musical. Ambos se asocian a patologías como la neumonía, la fibrosis pulmonar, el asma o la enfermedad pulmonar obstructiva crónica [2].

La principal limitación de la auscultación es su subjetividad: la interpretación de los sonidos depende en gran medida del entrenamiento y de la experiencia del profesional. En un estudio multicéntrico con más de 450 médicos en formación de medicina interna y medicina familiar, los participantes identificaron correctamente, en promedio, alrededor del 20 % de los eventos cardíacos que se les presentaron, sin mejoras significativas a medida que avanzaban en la residencia [3].

La aparición del estetoscopio electrónico modificó este escenario. Este dispositivo convierte la señal acústica en una señal eléctrica que puede amplificarse, filtrarse, almacenarse y transmitirse [4]. Contar con la auscultación como una señal digital

la vuelve compatible con las técnicas de procesamiento de señales y de aprendizaje automático. En particular, las redes neuronales profundas pueden aprender directamente, a partir de representaciones tiempo-frecuencia como el espectrograma, los patrones acústicos que caracterizan a cada patología. En la figura 1.1 se muestran ejemplos de estas representaciones para sonidos cardíacos y pulmonares, normales y patológicos. Este trabajo se sitúa en ese cruce entre la auscultación digital y la inteligencia artificial.

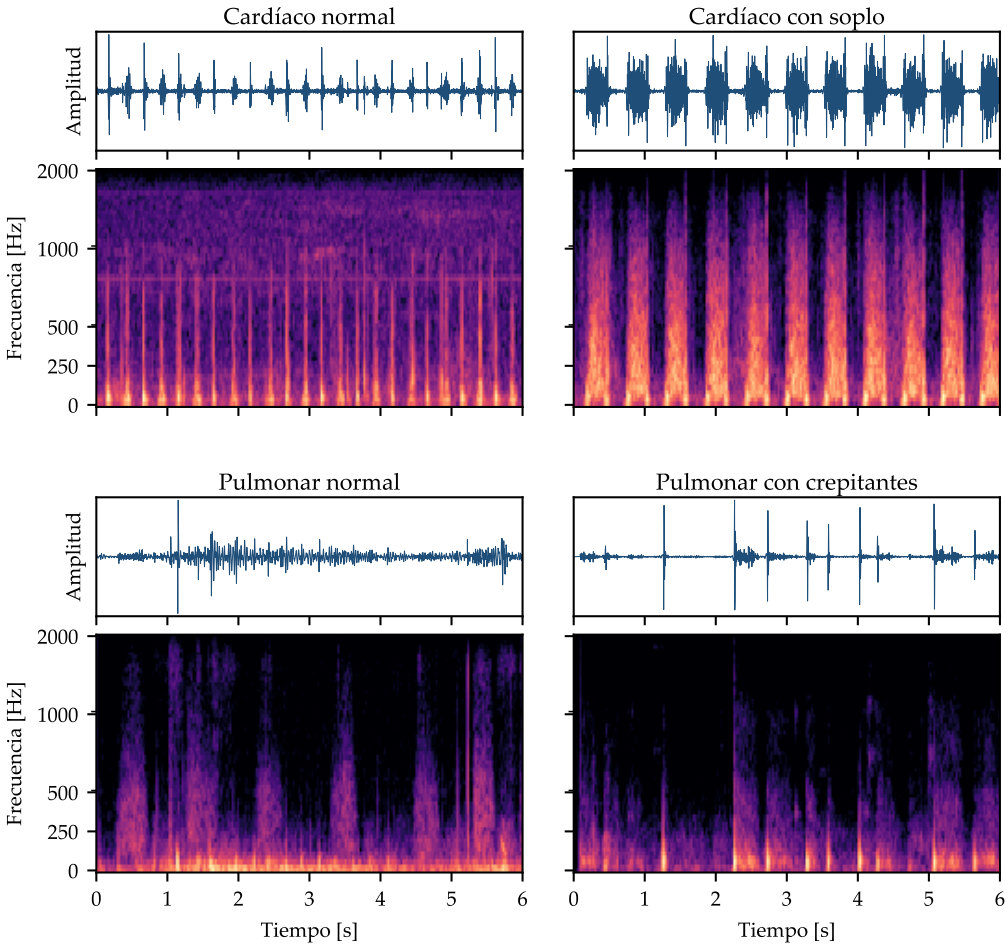


FIGURA 1.1. Forma de onda y espectrograma en escala Mel de cuatro grabaciones de auscultación: sonido cardíaco normal, sonido cardíaco con soplo, sonido pulmonar normal y sonido pulmonar con crepitantes.

1.2. Contexto y motivación

Las enfermedades cardiovasculares y respiratorias se encuentran entre las principales causas de muerte y de discapacidad en el mundo. Según la Organización Mundial de la Salud, en 2019 las enfermedades cardiovasculares causaron alrededor de 17,9 millones de muertes, el 32 % del total mundial, y más de tres cuartas partes de ellas ocurrieron en países de ingresos bajos y medios [5]. Por su parte, en 2017 se estimaba que unas 545 millones de personas vivían con alguna enfermedad respiratoria crónica, que en conjunto constituían la tercera causa de muerte a nivel mundial [6]. En ambos grupos de enfermedades, la detección temprana

resulta determinante para el pronóstico del paciente y para reducir los costos que la enfermedad avanzada impone al sistema de salud.

El acceso a esa detección temprana no es homogéneo. En América del Sur, los profesionales de la salud se concentran en las capitales y en las grandes ciudades, mientras que las zonas rurales y desatendidas sufren faltantes que afectan de manera directa la disponibilidad de especialistas [7]. En esos contextos, suele ser el médico generalista quien realiza la primera evaluación del paciente con el estetoscopio y quien decide, a partir de lo que escucha, si derivarlo o no a un cardiólogo o a un neumólogo. Como se señaló en la sección 1.1, la precisión de esa evaluación depende fuertemente del entrenamiento del profesional. Un soplo o un crepitante que pasan inadvertidos pueden retrasar el diagnóstico de una enfermedad tratable. A la inversa, una derivación innecesaria consume recursos escasos.

Este escenario motiva el desarrollo de herramientas de apoyo a la decisión clínica basadas en inteligencia artificial. Un sistema capaz de analizar la señal registrada por un estetoscopio digital y de indicar la presencia de hallazgos patológicos ofrecería al médico generalista una segunda opinión objetiva y reproducible, sin reemplazar su criterio. Además, en la práctica clínica el corazón y los pulmones se auscultan durante el mismo examen, por lo que resulta de interés que una misma herramienta pueda analizar ambos tipos de sonido.

El trabajo se desarrolló en el marco de la Carrera de Especialización en Inteligencia Artificial de la Universidad de Buenos Aires, en colaboración con el Centro de Investigación y Desarrollo en Ingeniería Biomédica (CIBIO) de la Universidad Tecnológica Nacional, Facultad Regional Buenos Aires. Sus resultados son de carácter académico y de acceso abierto, para que puedan incorporarse a futuras líneas de investigación clínica del centro. Desde el punto de vista del autor, el proyecto integra su experiencia previa en procesamiento digital de señales y en desarrollos aplicados al ámbito médico con las técnicas de aprendizaje profundo estudiadas durante la especialización.

1.3. Estado del arte

El análisis automático de sonidos de auscultación tuvo un fuerte crecimiento durante la última década, impulsado en buena medida por la publicación de bases de datos abiertas y por desafíos científicos que permitieron comparar algoritmos bajo condiciones comunes. En el dominio cardíaco se destacan el desafío PhysioNet/Computing in Cardiology 2016, orientado a distinguir grabaciones normales de anormales [8], y el George B. Moody PhysioNet Challenge 2022, centrado en la detección de soplos [9] sobre la base CirCor DigiScope, compuesta por grabaciones de pacientes pediátricos [10]. En el dominio pulmonar, la referencia principal es la base del desafío ICBHI 2017, con 920 grabaciones de 126 pacientes y anotaciones de crepitantes y sibilancias por ciclo respiratorio [11]. Revisiones recientes de ambos dominios muestran que el aprendizaje profundo desplazó a los métodos basados en características diseñadas manualmente [12, 13].

El enfoque predominante consiste en transformar la señal de audio en una representación tiempo-frecuencia, como el espectrograma en escala Mel o los coeficientes cepstrales en frecuencia Mel (MFCC, *Mel-Frequency Cepstral Coefficients*), y

procesarla con una red neuronal convolucional (CNN, *Convolutional Neural Network*). En el desafío de 2016, la mejor propuesta combinó un clasificador basado en características con una CNN [14], mientras que en el de 2022 el primer puesto en la detección de soplos correspondió a una CNN liviana que recibe el espectrograma Mel junto con datos demográficos del paciente [15]. En el dominio pulmonar, los trabajos más recientes incorporan transferencia de aprendizaje desde modelos preentrenados sobre grandes volúmenes de imágenes o de audio general. RespireNet adaptó una ResNet-34 preentrenada en ImageNet con técnicas de aumentación específicas para sonidos respiratorios [16], y trabajos posteriores emplearon arquitecturas basadas en *transformers*, como el *Audio Spectrogram Transformer*, combinadas con aprendizaje contrastivo [17]. La tabla 1.1 resume los trabajos más representativos.

TABLA 1.1. Comparación de trabajos representativos en la clasificación automática de sonidos de auscultación. Se informa la métrica principal de cada trabajo sobre su conjunto de prueba; los valores no son directamente comparables entre filas porque difieren las tareas, los datos y los protocolos de partición.

Trabajo	**Tarea**	**Datos**	**Modelo**	**Resultado**
Potes et al. [14]	Cardíaco: normal o anormal	PhysioNet/ CinC 2016	Ensamble de AdaBoost sobre características y CNN	Puntaje 0,860 (1.er puesto)
Lu et al. [15]	Cardíaco: soplo presente, ausente o desconocido	CirCor DigiScope	CNN liviana sobre espectrograma Mel y datos demográficos	Exactitud ponderada 0,780 (1.er puesto)
Gairola et al. [16]	Pulmonar: 4 clases de sonidos adventicios por ciclo	ICBHI 2017 (partición oficial)	ResNet-34 preentrenada en ImageNet	Puntaje ICBHI 56,2 % (Se 40,1 %, Sp 72,3 %)
Bae et al. [17]	Pulmonar: 4 clases de sonidos adventicios por ciclo	ICBHI 2017 (partición oficial)	*Audio Spectrogram Transformer* con aprendizaje contrastivo	Puntaje ICBHI 62,4 % (Se 43,1 %, Sp 81,7 %)
Tariq et al. [18]	Pulmonar y cardíaco, con un modelo para cada dominio	ICBHI 2017 y una base pública de 656 grabaciones cardíacas	Fusión de tres CNN (espectrograma, MFCC y cromagrama)	Exactitud 99,1 % (pulmonar) y 97 % (cardíaco)

La comparación entre trabajos debe hacerse con cautela. Cada desafío define su propia métrica: el de 2016 y el ICBHI utilizan el promedio entre sensibilidad (Se) y especificidad (Sp), mientras que el de 2022 emplea una exactitud ponderada que penaliza más los soplos no detectados. Además, la forma de particionar los datos influye fuertemente en los resultados. Sobre la partición oficial del ICBHI, los trabajos de la tabla 1.1 obtienen puntajes de entre el 56 y el 62 %, con sensibilidades por debajo del 45 %. En cambio, algunos trabajos informan exactitudes

cercanas al 99 % con una partición 80/20 de las grabaciones, sin indicar si las grabaciones de un mismo paciente quedan separadas entre entrenamiento y prueba [18]. Cuando esa separación no se garantiza, el modelo puede aprender características propias de cada paciente o de cada equipo de grabación, y el resultado sobreestima su desempeño ante pacientes nuevos.

Por último, la gran mayoría de los sistemas existentes aborda los sonidos cardíacos y pulmonares como dominios independientes: cada modelo se entrena con una única base de datos y reconoce solo patologías de un órgano. Incluso los trabajos que estudian ambos tipos de sonido, como el de Tariq et al., entrenan y evalúan un modelo distinto para cada dominio [18]. Esta separación contrasta con la práctica clínica, en la que el médico ausculta el corazón y los pulmones durante un mismo examen. Recién en los últimos años aparecieron bases de datos que registran ambos sonidos de forma conjunta, como HLS-CMDS, grabada sobre un maniquí clínico [19], lo que refleja un interés creciente por el análisis cardiopulmonar integrado. El presente trabajo se enfoca en ese vacío: abordar los sonidos cardíacos y pulmonares dentro de un mismo sistema de clasificación.

1.4. Objetivos y alcance

El objetivo general del trabajo fue desarrollar un sistema de clasificación automática de sonidos de auscultación basado en redes neuronales, capaz de detectar hallazgos patológicos tanto en sonidos cardíacos como pulmonares, como herramienta de apoyo al diagnóstico del médico generalista.

Para alcanzar este objetivo se plantearon los siguientes objetivos específicos:

1. Analizar las bases de datos públicas de sonidos cardíacos y pulmonares, caracterizando la distribución de clases, la calidad de las grabaciones y los desbalances que debían corregirse antes del modelado.
2. Implementar un proceso de preprocesamiento común a ambos tipos de sonido, que incluyera el remuestreo a una frecuencia única, la normalización de amplitud y la extracción de representaciones tiempo-frecuencia, como el espectrograma Mel y los MFCC.
3. Diseñar y entrenar modelos de clasificación basados en redes neuronales convolucionales para la detección de patologías cardíacas y pulmonares.
4. Comparar el desempeño de modelos entrenados por separado para cada tipo de sonido con el de un enfoque integrado, para determinar cuál resulta más adecuado.
5. Evaluar los modelos con particiones independientes por paciente, informando la exactitud, la sensibilidad, la especificidad, el F1-*score* por clase, la matriz de confusión y la curva ROC (*Receiver Operating Characteristic*), y analizar los errores en el contexto clínico del problema.
6. Comparar los resultados obtenidos con los trabajos del estado del arte presentados en la sección 1.3, identificando en qué aspectos el sistema los iguala, los supera o queda por debajo.

El alcance del trabajo comprendió la recopilación y el preprocesamiento de grabaciones provenientes de bases de datos públicas, la extracción de representaciones de la señal, el diseño, el entrenamiento y la validación de los modelos, y su

evaluación con métricas estándar. Quedaron fuera del alcance el desarrollo de *hardware* y la integración con un estetoscopio digital físico, la validación clínica con pacientes reales y la obtención de aprobaciones regulatorias, y el despliegue del sistema en un entorno de producción. Por último, el sistema fue concebido exclusivamente como una herramienta de apoyo: sus resultados no constituyen un diagnóstico definitivo ni reemplazan el criterio del profesional de la salud.

Capítulo 2

Introducción específica

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

2.1. Estilo y convenciones

2.1.1. Uso de mayúscula inicial para los título de secciones

Si en el texto se hace alusión a diferentes partes del trabajo referirse a ellas como capítulo, sección o subsección según corresponda. Por ejemplo: "En el capítulo 1 se explica tal cosa", o "En la sección 2.1 se presenta lo que sea", o "En la subsección 2.1.2 se discute otra cosa".

Cuando se quiere poner una lista tabulada, se hace así:

- Este es el primer elemento de la lista.
- Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

Si se desea poner una lista numerada el formato es este:

1. Este es el primer elemento de la lista.
2. Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

2.1.2. Este es el título de una subsección

Se recomienda no utilizar **texto en negritas** en ningún párrafo, ni tampoco texto subrayado. En cambio sí se debe utilizar *texto en itálicas* para palabras en un idioma extranjero, al menos la primera vez que aparecen en el texto. En el caso de palabras que estamos inventando se deben utilizar "comillas", así como también para citas textuales. Por ejemplo, un *digital filter* es una especie de "selector" que permite separar ciertos componentes armónicos en particular.

La escritura debe ser impersonal. Por ejemplo, no utilizar "el diseño del firmware lo hice de acuerdo con tal principio", sino "el firmware fue diseñado utilizando tal principio".

El trabajo es algo que al momento de escribir la memoria se supone que ya está concluido, entonces todo lo que se refiera a hacer el trabajo se narra en tiempo pasado, porque es algo que ya ocurrió. Por ejemplo, "se diseñó el firmware empleando la técnica de test driven development".

En cambio, la memoria es algo que está vivo cada vez que el lector la lee. Por eso transcurre siempre en tiempo presente, como por ejemplo:

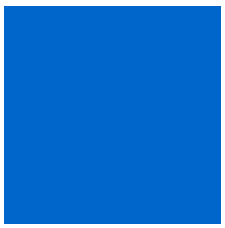
“En el presente capítulo se da una visión global sobre las distintas pruebas realizadas y los resultados obtenidos. Se explica el modo en que fueron llevados a cabo los test unitarios y las pruebas del sistema”.

Se recomienda no utilizar una sección de glosario sino colocar la descripción de las abreviaturas como parte del mismo cuerpo del texto. Por ejemplo, RTOS (*Real Time Operating System*, Sistema Operativo de Tiempo Real) o en caso de considerarlo apropiado mediante notas a pie de página.

Si se desea indicar alguna página web utilizar el siguiente formato de referencias bibliográficas, dónde las referencias se detallan en la sección de bibliografía de la memoria, utilizado el formato establecido por IEEE en [20]. Por ejemplo, “el presente trabajo se basa en la plataforma EDU-CIAA-NXP [21], la cual...”.

2.1.3. Figuras

Al insertar figuras en la memoria se deben considerar determinadas pautas. Para empezar, usar siempre tipografía claramente legible. Luego, tener claro que **es incorrecto** escribir por ejemplo esto: “El diseño elegido es un cuadrado, como se ve en la siguiente figura:”



La forma correcta de utilizar una figura es con referencias cruzadas, por ejemplo: “Se eligió utilizar un cuadrado azul para el logo, como puede observarse en la figura 2.1”.

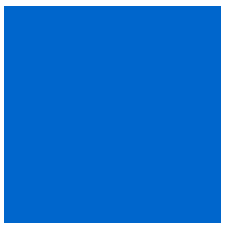


FIGURA 2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.

El texto de las figuras debe estar siempre en español, excepto que se decida reproducir una figura original tomada de alguna referencia. En ese caso la referencia de la cual se tomó la figura debe ser indicada en el epígrafe de la figura e incluida como una nota al pie, como se ilustra en la figura 2.2.



FIGURA 2.2. Imagen tomada de la página oficial del procesador[1].

La figura y el epígrafe deben conformar una unidad cuyo significado principal pueda ser comprendido por el lector sin necesidad de leer el cuerpo central de la memoria. Para eso es necesario que el epígrafe sea todo lo detallado que corresponda y si en la figura se utilizan abreviaturas entonces aclarar su significado en el epígrafe o en la misma figura.



FIGURA 2.3. ¿Por qué de pronto aparece esta figura?

Nunca colocar una figura en el documento antes de hacer la primera referencia a ella, como se ilustra con la figura 2.3, porque sino el lector no comprenderá por qué de pronto aparece la figura en el documento, lo que distraerá su atención.

Otra posibilidad es utilizar el entorno *subfigure* para incluir más de una figura, como se puede ver en la figura 2.4. Notar que se pueden referenciar también las figuras internas individualmente de esta manera: 2.4a, 2.4b y 2.4c.



(A) Un caption.



(B) Otro.



(C) Y otro más.

FIGURA 2.4. Tres gráficos simples.

El código para generar las imágenes se encuentra disponible para su reutilización en el archivo **`Chapter2.tex`**.

2.1.4. Tablas

Para las tablas utilizar el mismo formato que para las figuras, sólo que el epígrafe se debe colocar arriba de la tabla, como se ilustra en la tabla 2.1. Observar que sólo algunas filas van con líneas visibles y notar el uso de las negritas para los encabezados. La referencia se logra utilizando el comando `\ref{<label>}` donde label debe estar definida dentro del entorno de la tabla.

[1]Imagen tomada de https://goo.gl/images/i7C70w

```
\begin{table}[h]
 \centering
 \caption[caption corto]{caption largo más descriptivo}
 \begin{tabular}{l c c}
  \toprule
  \textbf{Especie}     & \textbf{Tamaño} & \textbf{Valor}\\
  \midrule
  Amphiprion Ocellaris & 10 cm           & \$ 6.000 \\
  Hepatus Blue Tang    & 15 cm           & \$ 7.000 \\
  Zebrasoma Xanthurus  & 12 cm           & \$ 6.800 \\
  \bottomrule
  \hline
 \end{tabular}
 \label{tab:peces}
\end{table}
```

TABLA 2.1. caption largo más descriptivo.

Especie	**Tamaño**	**Valor**
Amphiprion Ocellaris	10 cm	$ 6.000
Hepatus Blue Tang	15 cm	$ 7.000
Zebrasoma Xanthurus	12 cm	$ 6.800

En cada capítulo se debe reiniciar el número de conteo de las figuras y las tablas, por ejemplo, figura 2.1 o tabla 2.1, pero no se debe reiniciar el conteo en cada sección. Por suerte la plantilla se encarga de esto por nosotros.

2.1.5. Ecuaciones

Al insertar ecuaciones en la memoria dentro de un entorno *equation*, éstas se numeran en forma automática y se pueden referir al igual que como se hace con las figuras y tablas, por ejemplo ver la ecuación 2.1.

$$ds^2 = c^2 dt^2 \left(\frac{d\sigma^2}{1 - k\sigma^2} + \sigma^2 \left[d\theta^2 + \sin^2 \theta d\phi^2 \right] \right) \tag{2.1}$$

Para generar la ecuación 2.1 se utilizó el siguiente código:

```
\begin{equation}
 \label{eq:metric}
 ds^2 = c^2 dt^2 \left( \frac{d\sigma^2}{1-k\sigma^2} +
 \sigma^2\left[ d\theta^2 +
 \sin^2\theta d\phi^2 \right] \right)
\end{equation}
```

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno lstlisting con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
 las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código 3.1:

```
#define MAX_SENSOR_NUMBER 3
#define MAX_ALARM_NUMBER  6
#define MAX_ACTUATOR_NUMBER 6

uint32_t sensorValue[MAX_SENSOR_NUMBER];
FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
state_t alarmState[MAX_ALARM_NUMBER];           //ON or OFF
state_t actuatorState[MAX_ACTUATOR_NUMBER];     //ON or OFF

void vControl() {

  initGlobalVariables();

  period = 500 ms;

  while(1) {

    ticks = xTaskGetTickCount();

    updateSensors();

    updateAlarms();

    controlActuators();

    vTaskDelayUntil(&ticks, period);
  }
```

```
28 }
```

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se puedo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

[1] Ariel Roguin. «Rene Theophile Hyacinthe Laënnec (1781–1826): The Man Behind the Stethoscope». En: *Clinical Medicine & Research* 4.3 (2006), págs. 230-235. DOI: 10.3121/cmr.4.3.230.

[2] Abraham Bohadana, Gabriel Izbicki y Steve S. Kraman. «Fundamentals of Lung Auscultation». En: *New England Journal of Medicine* 370.8 (2014), págs. 744-751. DOI: 10.1056/NEJMra1302901.

[3] Salvatore Mangione y Linda Z. Nieman. «Cardiac Auscultatory Skills of Internal Medicine and Family Practice Trainees: A Comparison of Diagnostic Proficiency». En: *JAMA* 278.9 (1997), págs. 717-722. DOI: 10.1001/jama.1997.03550090041030.

[4] Shuang Leng et al. «The Electronic Stethoscope». En: *BioMedical Engineering OnLine* 14.1 (2015), pág. 66. DOI: 10.1186/s12938-015-0056-y.

[5] World Health Organization. *Cardiovascular diseases (CVDs) – Fact sheet*. 2021. URL: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds) (visitado 25-10-2026).

[6] GBD Chronic Respiratory Disease Collaborators. «Prevalence and attributable health burden of chronic respiratory diseases, 1990–2017: a systematic analysis for the Global Burden of Disease Study 2017». En: *The Lancet Respiratory Medicine* 8.6 (2020), págs. 585-596. DOI: 10.1016/S2213-2600(20)30105-3.

[7] Organización Panamericana de la Salud. *PAHO warns of critical gaps in the health labor market in nine South American countries*. 2026. URL: https://www.paho.org/en/news/29-4-2026-paho-warns-critical-gaps-health-labor-market-nine-south-american-countries (visitado 25-10-2026).

[8] Gari D. Clifford et al. «Classification of Normal/Abnormal Heart Sound Recordings: the PhysioNet/Computing in Cardiology Challenge 2016». En: *2016 Computing in Cardiology Conference (CinC)*. Vol. 43. 2016. DOI: 10.22489/CinC.2016.179-154.

[9] Matthew A. Reyna et al. «Heart murmur detection from phonocardiogram recordings: The George B. Moody PhysioNet Challenge 2022». En: *PLOS Digital Health* 2.9 (2023), e0000324. DOI: 10.1371/journal.pdig.0000324.

[10] Jorge Oliveira et al. «The CirCor DigiScope Dataset: From Murmur Detection to Murmur Classification». En: *IEEE Journal of Biomedical and Health Informatics* 26.6 (2022), págs. 2524-2535. DOI: 10.1109/JBHI.2021.3137048.

[11] Bruno M. Rocha et al. «An open access database for the evaluation of respiratory sound classification algorithms». En: *Physiological Measurement* 40.3 (2019), pág. 035001. DOI: 10.1088/1361-6579/ab03ea.

[12] Zhao Ren et al. «A Comprehensive Survey on Heart Sound Analysis in the Deep Learning Era». En: *IEEE Computational Intelligence Magazine* 19.3 (2024), págs. 42-57. DOI: 10.1109/MCI.2024.3401309.

[13] Alyaa Hamel Sfayyih, Nasri Sulaiman y Ahmad H. Sabry. «A review on lung disease recognition by acoustic signal analysis with deep learning networks». En: *Journal of Big Data* 10 (2023), pág. 101. DOI: 10.1186/s40537-023-00762-z.

[14] Cristhian Potes et al. «Ensemble of Feature-based and Deep learning-based Classifiers for Detection of Abnormal Heart Sounds». En: *2016 Computing in Cardiology Conference (CinC)*. Vol. 43. 2016. DOI: 10.22489/CinC.2016.182-399.

[15] Hui Lu et al. «A Lightweight Robust Approach for Automatic Heart Murmurs and Clinical Outcomes Classification from Phonocardiogram Recordings». En: *2022 Computing in Cardiology Conference (CinC)*. Vol. 49. 2022. DOI: 10.22489/CinC.2022.165.

[16] Siddhartha Gairola et al. «RespireNet: A Deep Neural Network for Accurately Detecting Abnormal Lung Sounds in Limited Data Setting». En: *2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*. 2021, págs. 527-530. DOI: 10.1109/EMBC46164.2021.9630091.

[17] Sangmin Bae et al. «Patch-Mix Contrastive Learning with Audio Spectrogram Transformer on Respiratory Sound Classification». En: *Proc. Interspeech 2023*. 2023, págs. 5436-5440. DOI: 10.21437/Interspeech.2023-1426.

[18] Zeenat Tariq, Sayed Khushal Shah y Yugyung Lee. «Feature-Based Fusion Using CNN for Lung and Heart Sound Classification». En: *Sensors* 22.4 (2022), pág. 1521. DOI: 10.3390/s22041521.

[19] Yasaman Torabi, Shahram Shirani y James P. Reilly. «Descriptor: Heart and Lung Sounds Dataset Recorded From a Clinical Manikin Using Digital Stethoscope (HLS-CMDS)». En: *IEEE Data Descriptions* 2 (2025), págs. 133-140. DOI: 10.1109/IEEEDATA.2025.3566012.

[20] IEEE. *IEEE Citation Reference*. 1.ª ed. IEEE Publications, 2016. URL: http://www.ieee.org/documents/ieeecitationref.pdf (visitado 26-09-2016).

[21] Proyecto CIAA. *Computadora Industrial Abierta Argentina*. Visitado el 2016-06-25. 2014. URL: http://proyecto-ciaa.com.ar/devwiki/doku.php?id=start.