.UBAfiuba
FACULTAD DE INGENIERÍA

Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación

Ing. Santiago Federico Bettig

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Ing. Leandro Javier Cymberknop (CIBIO, UTN FRBA)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Buenos Aires, mayo de 2027

Resumen

En esta memoria se presenta el desarrollo de un sistema de clasificación automática de sonidos de auscultación cardíaca y pulmonar basado en redes neuronales, concebido como herramienta de apoyo al diagnóstico para el médico generalista. El sistema procesa grabaciones obtenidas con estetoscopios digitales, las transforma en representaciones tiempo-frecuencia y detecta la presencia de hallazgos patológicos en ambos tipos de sonido. A diferencia de la mayoría de los estudios previos que tratan los sonidos cardíacos y pulmonares por separado, el trabajo aborda la auscultación cardiopulmonar de forma integrada y compara este enfoque con el de modelos independientes para cada órgano. El trabajo se realizó en colaboración con el Centro de Investigación y Desarrollo en Ingeniería Biomédica de la Universidad Tecnológica Nacional.

En el desarrollo se aplicaron contenidos de la especialización vinculados con el análisis de datos, el aprendizaje automático, el aprendizaje profundo, las redes neuronales convolucionales y la gestión de proyectos.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. La auscultación cardiopulmonar 1
1.2. Contexto y motivación 2
1.3. Estado del arte 3
1.4. Objetivos y alcance 5

2. Introducción específica 7
2.1. Alteraciones acústicas buscadas 7
2.1.1. Alteraciones en los sonidos cardíacos 7
2.1.2. Alteraciones en los sonidos pulmonares 7
2.1.3. Clases consideradas 8
2.2. Herramientas y entorno de cómputo 9
2.3. Bases de datos 9
2.3.1. CirCor DigiScope 10
2.3.2. SPRSound 11
2.3.3. ICBHI 2017 11
2.3.4. HLS-CMDS 11
2.4. Modelo preentrenado 11

3. Diseño e implementación 13

4. Ensayos y resultados 15

5. Conclusiones 17

Bibliografía 19

Índice de figuras

1.1. Forma de onda y espectrogramas de cuatro grabaciones de auscultación 2

2.1. Ejemplos de las alteraciones acústicas buscadas 8

Índice de tablas

1.1. Comparación de trabajos representativos del estado del arte 4

2.1. Herramientas de software utilizadas 9
2.2. Características de las bases de datos utilizadas 10
2.3. Características del modelo preentrenado CNN6 12

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presenta el área en la que se enmarca el trabajo, el contexto y la motivación que le dieron origen, una revisión del estado del arte en la clasificación automática de sonidos de auscultación, los objetivos y el alcance del proyecto.

1.1. La auscultación cardiopulmonar

La auscultación es la técnica de exploración clínica que consiste en escuchar los sonidos generados en el interior del cuerpo, principalmente los del corazón y los pulmones. Desde que René Laënnec inventó el estetoscopio en 1816 y lo utilizó para vincular los sonidos torácicos con los hallazgos de autopsia [1], la auscultación se convirtió en uno de los pilares del examen físico. Su vigencia se explica por tres características: es no invasiva, tiene un costo muy bajo y brinda información inmediata en el lugar de atención.

Los sonidos cardíacos normales se originan principalmente en el cierre de las válvulas y se perciben como dos golpes breves por ciclo, conocidos como primer y segundo ruido (S1 y S2). Distintas alteraciones modifican este patrón. Los soplos son sonidos producidos por el flujo turbulento de la sangre y se asocian, por ejemplo, a valvulopatías o a cardiopatías congénitas. También pueden aparecer ruidos adicionales, como el tercer y el cuarto ruido (S3 y S4), o irregularidades del ritmo. En el caso de los pulmones, el flujo de aire durante la respiración produce los ruidos respiratorios normales. Sobre ellos pueden superponerse sonidos adventicios, como los crepitantes, que son eventos discontinuos y de muy corta duración, y las sibilancias, que son sonidos continuos de carácter musical. Ambos se asocian a patologías como la neumonía, la fibrosis pulmonar, el asma o la enfermedad pulmonar obstructiva crónica [2].

La principal limitación de la auscultación es su subjetividad, ya que la interpretación de los sonidos depende en gran medida del entrenamiento y de la experiencia del profesional. En un estudio multicéntrico con más de 450 médicos en formación de medicina interna y medicina familiar, los participantes identificaron correctamente, en promedio, alrededor del 20 % de los eventos cardíacos que se les presentaron, sin mejoras significativas a medida que avanzaban en la residencia [3].

La aparición del estetoscopio electrónico modificó este escenario. Este dispositivo convierte la señal acústica en una señal eléctrica que puede amplificarse, filtrarse, almacenarse y transmitirse [4]. Contar con la auscultación como una señal digital

la vuelve útil para aplicar técnicas de procesamiento de señales y de aprendizaje automático. En particular, las redes neuronales profundas pueden aprender directamente, a partir de representaciones tiempo-frecuencia, los patrones acústicos que caracterizan a cada patología. En la figura 1.1 se muestran ejemplos de estas representaciones para sonidos cardíacos y pulmonares, normales y patológicos. Este trabajo se sitúa en ese cruce entre la auscultación digital y la inteligencia artificial.

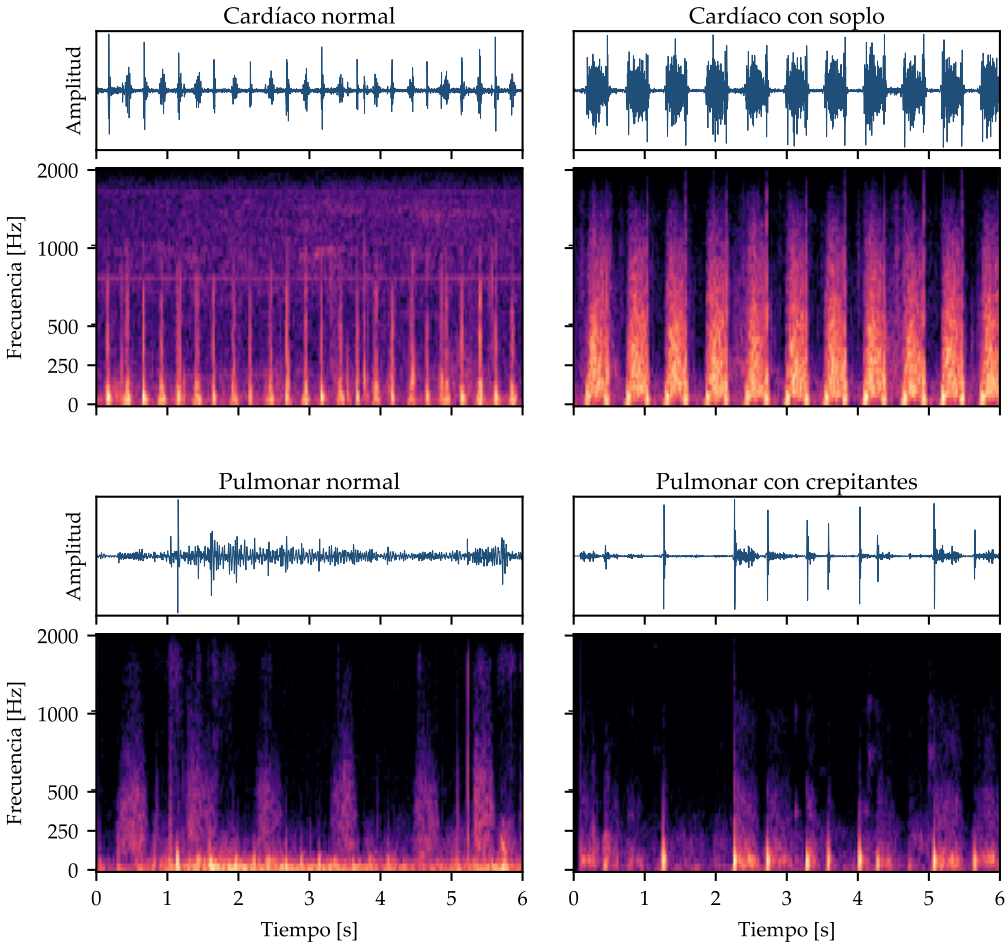


FIGURA 1.1. Forma de onda y espectrogramas de cuatro grabaciones de auscultación

1.2. Contexto y motivación

Las enfermedades cardiovasculares y respiratorias se encuentran entre las principales causas de muerte y de discapacidad en el mundo. Según la Organización Mundial de la Salud, en 2019 las enfermedades cardiovasculares causaron alrededor de 17,9 millones de muertes, el 32 % del total mundial, y más de tres cuartas partes de ellas ocurrieron en países de ingresos bajos y medios [5]. Por su parte, en 2017 se estimaba que unos 545 millones de personas vivían con alguna enfermedad respiratoria crónica, que en conjunto constituían la tercera causa de muerte a nivel mundial [6]. En ambos grupos de enfermedades, la detección temprana resulta determinante para el pronóstico del paciente y para reducir los costos que la enfermedad avanzada impone al sistema de salud.

El acceso a esa detección temprana no es homogéneo. En América del Sur, los profesionales de la salud se concentran en las capitales y en las grandes ciudades, mientras que las zonas rurales y desatendidas sufren faltantes que afectan de manera directa la disponibilidad de especialistas [7]. En esos contextos, suele ser el médico generalista quien realiza la primera evaluación del paciente con el estetoscopio y quien decide, a partir de lo que escucha, si derivarlo o no a un cardiólogo o a un neumólogo. Como se señaló en la sección 1.1, la precisión de esa evaluación depende fuertemente del entrenamiento del profesional. Un soplo o un crepitante que pasan inadvertidos pueden retrasar el diagnóstico de una enfermedad tratable. A la inversa, una derivación innecesaria consume recursos escasos.

Este escenario motiva el desarrollo de herramientas de apoyo a la decisión clínica basadas en inteligencia artificial. Un sistema capaz de analizar la señal registrada por un estetoscopio digital y de indicar la presencia de hallazgos patológicos ofrecería al médico generalista una segunda opinión objetiva y reproducible, sin reemplazar su criterio. Además, en la práctica clínica, el corazón y los pulmones se auscultan durante el mismo examen, por lo que resulta de interés que una misma herramienta pueda analizar ambos tipos de sonido.

El trabajo se desarrolló en el marco de la Carrera de Especialización en Inteligencia Artificial de la Universidad de Buenos Aires, en colaboración con el Centro de Investigación y Desarrollo en Ingeniería Biomédica (CIBIO) de la Universidad Tecnológica Nacional, Facultad Regional Buenos Aires. Sus resultados son de carácter académico y de acceso abierto, para que puedan incorporarse a futuras líneas de investigación clínica del centro. El proyecto integra procesamiento digital de señales y desarrollo aplicado al ámbito médico, con las técnicas de aprendizaje profundo estudiadas durante la especialización.

1.3. Estado del arte

El análisis automático de sonidos de auscultación tuvo un fuerte crecimiento durante la última década, impulsado en buena medida por la publicación de bases de datos abiertas y por desafíos científicos que permitieron comparar algoritmos bajo condiciones comunes. En el dominio cardíaco se destacan el desafío PhysioNet/Computing in Cardiology 2016, orientado a distinguir grabaciones normales de anormales [8], y el George B. Moody PhysioNet Challenge 2022, centrado en la detección de soplos [9] sobre la base CirCor DigiScope, compuesta por grabaciones de pacientes pediátricos [10]. En el dominio pulmonar, la referencia principal es la base del desafío ICBHI 2017, con 920 grabaciones de 126 pacientes y anotaciones de crepitantes y sibilancias por ciclo respiratorio [11]. Más recientemente se publicó SPRSound, presentada por sus autores como la primera base abierta de sonidos respiratorios pediátricos, con anotaciones de eventos realizadas por médicos pediatras, que se utiliza desde 2022 en los desafíos de sonidos respiratorios de la conferencia IEEE BioCAS [12]. Revisiones recientes de ambos dominios muestran que el aprendizaje profundo desplazó a los métodos basados en características diseñadas manualmente [13, 14].

El enfoque predominante consiste en transformar la señal de audio en una representación tiempo-frecuencia, como el espectrograma en escala Mel o los coeficientes cepstrales en frecuencia Mel (MFCC, *Mel-Frequency Cepstral Coefficients*)

[15], y procesarla con una red neuronal convolucional (CNN, *Convolutional Neural Network*). En el desafío de 2016, la mejor propuesta combinó un clasificador basado en características con una CNN [16], mientras que en el de 2022 el primer puesto en la detección de soplos correspondió a una CNN liviana que recibe el espectrograma Mel junto con datos demográficos del paciente [17]. En el dominio pulmonar, los trabajos más recientes incorporan transferencia de aprendizaje desde modelos preentrenados sobre grandes volúmenes de imágenes o de audio general. RespireNet adaptó una ResNet-34 preentrenada en ImageNet con técnicas de aumentación específicas para sonidos respiratorios [18], y trabajos posteriores emplearon arquitecturas basadas en *transformers*, como el *Audio Spectrogram Transformer*, combinadas con aprendizaje contrastivo [19]. La tabla 1.1 resume los trabajos más representativos.

TABLA 1.1. Comparación de trabajos representativos en la clasificación automática de sonidos de auscultación. Se informa la métrica principal de cada trabajo sobre su conjunto de prueba; los valores no son directamente comparables entre filas porque difieren las tareas, los datos y los protocolos de partición.

Trabajo	**Tarea**	**Datos**	**Modelo**	**Resultado**
Potes et al.	Cardíaco: normal o anormal	PhysioNet/ CinC 2016	Ensamble de AdaBoost sobre características y CNN	Puntaje 0,860 (1er puesto)
Lu et al.	Cardíaco: soplo presente, ausente o desconocido	CirCor DigiScope	CNN liviana sobre espectrograma Mel y datos demográficos	Exactitud ponderada 0,780 (1er puesto)
Gairola et al.	Pulmonar: 4 clases de sonidos adventicios por ciclo	ICBHI 2017 (partición oficial)	ResNet-34 preentrenada en ImageNet	Puntaje ICBHI 56,2 % (Se 40,1 %, Sp 72,3 %)
Bae et al.	Pulmonar: 4 clases de sonidos adventicios por ciclo	ICBHI 2017 (partición oficial)	*Audio Spectrogram Transformer* con aprendizaje contrastivo	Puntaje ICBHI 62,4 % (Se 43,1 %, Sp 81,7 %)
Tariq et al.	Pulmonar y cardíaco, con un modelo para cada dominio	ICBHI 2017 y una base pública de 656 grabaciones cardíacas	Fusión de tres CNN (espectrograma, MFCC y cromagrama)	Exactitud 99,1 % (pulmonar) y 97 % (cardíaco)

La comparación entre trabajos debe hacerse con cautela. Cada desafío define su propia métrica: el de 2016 y el ICBHI utilizan el promedio entre sensibilidad (Se) y especificidad (Sp), mientras que el de 2022 emplea una exactitud ponderada que penaliza más los soplos no detectados. Además, la forma de particionar los datos influye fuertemente en los resultados. Sobre la partición oficial del ICBHI, los trabajos de la tabla 1.1 obtienen puntajes de entre el 56 y el 62 %, con sensibilidades por debajo del 45 %. En cambio, algunos trabajos informan exactitudes

cercanas al 99 % con una partición 80/20 de las grabaciones, sin indicar si las grabaciones de un mismo paciente quedan separadas entre entrenamiento y prueba [20]. Cuando esa separación no se garantiza, el modelo puede aprender características propias de cada paciente o de cada equipo de grabación y el resultado sobreestima su desempeño ante pacientes nuevos.

Por último, la gran mayoría de los sistemas existentes abordan los sonidos cardíacos y pulmonares como dominios independientes: cada modelo se entrena con una única base de datos y reconoce solo patologías de un órgano. Incluso los trabajos que estudian ambos tipos de sonido, como el de Tariq et al., entrenan y evalúan un modelo distinto para cada dominio. Esta separación contrasta con la práctica clínica, en la que el médico ausculta el corazón y los pulmones durante un mismo examen. Recién en los últimos años aparecieron bases de datos que registran ambos sonidos de forma conjunta, como HLS-CMDS, grabada sobre un maniquí clínico [21], lo que refleja un interés creciente por el análisis cardiopulmonar integrado. El presente trabajo se enfoca en ese vacío: abordar los sonidos cardíacos y pulmonares dentro de un mismo sistema de clasificación.

1.4. Objetivos y alcance

El objetivo del trabajo fue desarrollar un sistema de clasificación automática de sonidos de auscultación basado en redes neuronales, capaz de detectar hallazgos patológicos tanto en sonidos cardíacos como pulmonares, que sirva como herramienta de apoyo al diagnóstico del médico generalista.

Para alcanzar este objetivo se plantearon los siguientes objetivos:

1. Analizar las bases de datos públicas de sonidos cardíacos y pulmonares. Caracterizar la distribución de clases, la calidad de las grabaciones y los desbalances que debían corregirse antes del modelado.
2. Implementar un proceso de preprocesamiento común a ambos tipos de sonido, que incluyera el remuestreo a una frecuencia única, la normalización de amplitud y la extracción de representaciones tiempo-frecuencia, como el espectrograma Mel y los MFCC.
3. Diseñar y entrenar modelos de clasificación basados en redes neuronales convolucionales para la detección de patologías cardíacas y pulmonares.
4. Comparar el desempeño de modelos entrenados por separado para cada tipo de sonido con el de un enfoque integrado, para determinar cuál resulta más adecuado.
5. Evaluar los modelos y analizar los errores en el contexto clínico del problema con particiones independientes por paciente e informar la exactitud, la sensibilidad, la especificidad, el F1-score por clase, la matriz de confusión y la curva ROC (*Receiver Operating Characteristic*).
6. Comparar los resultados obtenidos con los trabajos del estado del arte presentados en la sección 1.3 e identificar en qué aspectos el sistema los iguala, los supera o queda por debajo.

El alcance del trabajo comprendió la recopilación y el preprocesamiento de grabaciones provenientes de bases de datos públicas, la extracción de representaciones de la señal, el diseño, el entrenamiento y la validación de los modelos, y su

evaluación con métricas estándar. Quedaron fuera del alcance el desarrollo de hardware y la integración con un estetoscopio digital físico, la validación clínica con pacientes reales y la obtención de aprobaciones regulatorias, y el despliegue del sistema en un entorno de producción. Por último, el sistema fue concebido exclusivamente como una herramienta de apoyo, por lo que sus resultados no constituyen un diagnóstico definitivo ni reemplazan el criterio del profesional de la salud.

Capítulo 2

Introducción específica

En este capítulo se describen los elementos en los que se apoya el desarrollo del trabajo. En primer lugar, se presentan las alteraciones acústicas que el sistema busca detectar. Luego, se mencionan las herramientas y el entorno de cómputo utilizados, se describen las bases de datos públicas empleadas para el entrenamiento y validación, y se presenta el modelo preentrenado utilizado como punto de partida para la transferencia de aprendizaje.

2.1. Alteraciones acústicas buscadas

Como se mencionó en la sección 1.1, cada patología modifica el sonido de auscultación de una manera particular. En esta sección se describen las alteraciones que el sistema debe reconocer tanto en tiempo como en frecuencia, ya que estas determinan qué información debe conservar la representación de la señal.

2.1.1. Alteraciones en los sonidos cardíacos

La alteración cardíaca considerada en este trabajo es el soplo. A diferencia de S1 y S2, que son eventos breves, el soplo se prolonga durante parte de la sístole, de la diástole, o incluso durante toda la fase. Por esa razón, se lo describe a partir de su ubicación dentro del ciclo cardíaco, su forma, su tono, su calidad y su intensidad, que suele graduarse con la escala de Levine [10].

Los soplos son frecuentes en niños sanos y la mayoría no se debe a una patología. Sin embargo, un soplo puede ser la única manifestación de una enfermedad cardíaca grave. Los soplos holosistólicos o diastólicos, la intensidad de grado 3 o superior y la calidad áspera aumentan la probabilidad de que el soplo sea patológico [22]. Las diferencias también se observan en el espectro. En un estudio con 807 pacientes pediátricos, los soplos inocentes se concentraron típicamente por debajo de los 200 Hz, mientras que los patológicos abarcaron tanto frecuencias más bajas como más altas [23].

En este trabajo, el modelo detecta la presencia de un soplo y no determina si es inocente o patológico. Por lo tanto, una detección positiva no constituye un diagnóstico, sino una indicación de que el paciente requiere una evaluación adicional por parte del profesional.

2.1.2. Alteraciones en los sonidos pulmonares

Los sonidos adventicios pulmonares se dividen en discontinuos y continuos. Los crepitantes pertenecen al primer grupo. Son eventos explosivos, de menos de

20 ms de duración, cuya energía se distribuye principalmente entre 60 y 1200 Hz. Según la teoría, se producen cuando las pequeñas vías aéreas colapsadas se abren de forma súbita durante la inspiración. Se clasifican en finos, que son suaves, agudos y más numerosos en cada respiración, y gruesos, que son fuertes, graves y menos numerosos. Los primeros se observan en enfermedades pulmonares intersticiales y los segundos, en la bronquitis crónica [24].

Las sibilancias pertenecen al grupo de los sonidos continuos. Son sonidos agudos, de carácter musical, con una frecuencia dominante de 400 Hz o más y una duración típicamente superior a 80-100 ms. Se atribuyen a la oscilación de las paredes bronquiales provocada por el flujo de aire y son características de la obstrucción generalizada de la vía aérea, como ocurre en el asma y en la enfermedad pulmonar obstructiva crónica. Los roncus son sonidos continuos similares, pero más graves, con una frecuencia dominante de alrededor de 200 Hz o menos [24].

Estas diferencias se reflejan en la representación tiempo-frecuencia, como se ilustra en la figura 2.1. El soplo ocupa el intervalo entre S1 y S2 con energía distribuida en un rango amplio de frecuencias. Los crepitantes aparecen como trazos verticales breves y de banda ancha. Las sibilancias, por su carácter tonal y sostenido, aparecen como trazos horizontales.

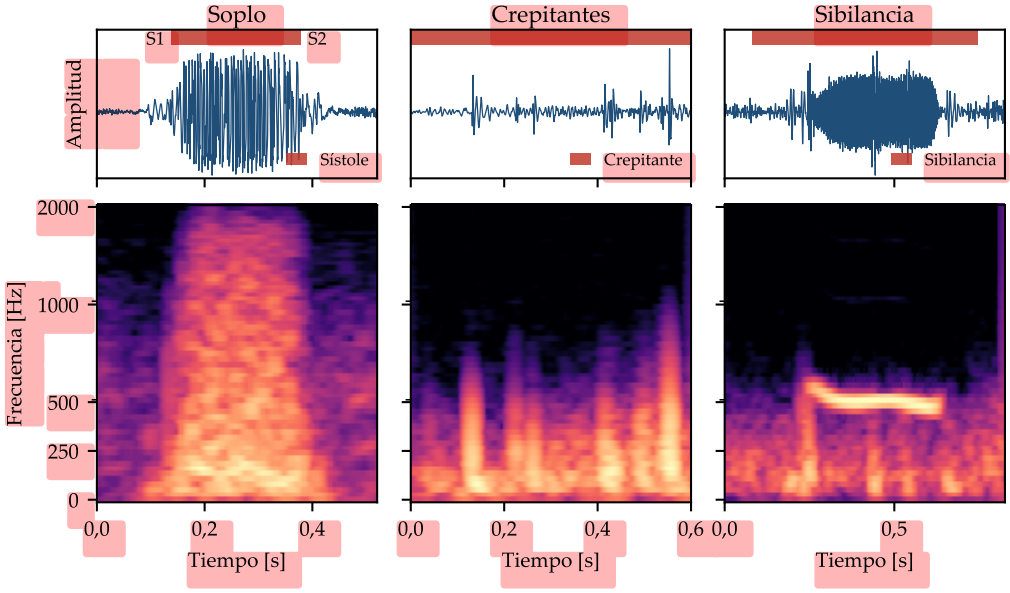


FIGURA 2.1. Forma de onda y espectrograma de un tramo de cada alteración buscada.

2.1.3. Clases consideradas

A partir de estas alteraciones, el modelo se diseñó para distinguir las siguientes seis clases:

- Sonido cardíaco normal.
- Sonido cardíaco con soplo.
- Sonido pulmonar normal.
- Sonido pulmonar con crepitantes.

- Sonido pulmonar con sibilancias.
- Sonido pulmonar con crepitantes y sibilancias.

Los crepitantes finos y gruesos se agruparon en una misma clase. Los roncus se incluyeron en la clase de sibilancias, ya que ambos son sonidos continuos. La última clase representa los casos en los que las dos alteraciones aparecen de forma conjunta. Además, esta agrupación permite unificar las etiquetas de las distintas bases de datos, que se describen en la sección 2.3.

2.2. Herramientas y entorno de cómputo

El trabajo se desarrolló en el lenguaje Python, que concentra la mayor parte de las bibliotecas de aprendizaje automático y de procesamiento de audio. Los modelos se implementaron, entrenaron y evaluaron con PyTorch [25]. Para la lectura de las grabaciones, el remuestreo y el cálculo de las representaciones tiempo-frecuencia se utilizó librosa [26], complementada con SciPy para el filtrado de las señales. Las métricas de evaluación se calcularon con scikit-learn [27], mientras que la manipulación de los datos y de los metadatos de cada base se realizó con NumPy [28] y pandas, y las figuras se generaron con Matplotlib. La tabla 2.1 resume las versiones utilizadas.

TABLA 2.1. Herramientas de software utilizadas y su función en el trabajo.

Herramienta	Versión	Uso
Python	3.12	Lenguaje de programación
PyTorch	2.13	Definición, entrenamiento e inferencia de los modelos
librosa	1.0	Carga de audio, remuestreo y espectrogramas Mel
SciPy	1.18	Filtrado de señales
scikit-learn	1.9	Métricas de evaluación
NumPy	2.5	Cálculo numérico
pandas	3.0	Manejo de datos tabulares y metadatos
Matplotlib	3.11	Generación de figuras

La mayor parte del trabajo se realizó en una computadora portátil con un procesador Intel Core i7-1355U y 16 GB de memoria RAM, sin una unidad de procesamiento gráfico (GPU, *Graphics Processing Unit*) dedicada. En ella se ejecutaron el preprocesamiento de los datos, el entrenamiento de los modelos y la evaluación de los mismos. Para el ajuste fino del modelo preentrenado, cuyo costo de cómputo resultaba inviable sin aceleración por *hardware*, se utilizó Google Colab, una plataforma en la nube que ofrece *notebooks* de Python con acceso a GPU. En particular, se empleó una GPU NVIDIA Tesla T4.

2.3. Bases de datos

Se utilizaron cuatro bases de datos públicas, cuyas características se resumen en la tabla 2.2. Dos de ellas, CirCor DigiScope y SPRSound, se emplearon para entrenar y evaluar los modelos. Ambas están compuestas por grabaciones de pacientes pediátricos, una para los sonidos cardíacos y otra para los pulmonares. Las otras dos, ICBHI 2017 y HLS-CMDS, se reservaron para evaluar los modelos con datos

provenientes de otras poblaciones y de otros equipos de grabación. No se utilizaron datos propios.

TABLA 2.2. Características de las bases de datos utilizadas.

	CirCor DigiScope	**SPRSound**	**ICBHI 2017**	**HLS-CMDS**
Uso	Entrenamiento	Entrenamiento	Validación externa	Validación externa
Sonido	Cardíaco	Pulmonar	Pulmonar	Cardíaco, pulmonar y mezclas
Origen	Paraíba, Brasil	Shanghái, China	Portugal y Grecia	Maniquí clínico
Población	Pediátrica (neonatos a adolescentes)	Pediátrica (0 a 16,8 años)	Todas las edades (0,25 a 93 años)	No aplica
Pacientes	942	952	126	No aplica
Grabaciones	3163	6567	920	535
Duración total	20,1 h	20,8 h	5,5 h	2,2 h
Frecuencia de muestreo	4 kHz	8 kHz	4, 10 y 44,1 kHz	4 kHz
Anotación	Soplo por paciente; segmentación del ciclo cardíaco	Etiqueta por grabación; eventos con inicio y fin	Crepitantes y sibilancias por ciclo respiratorio	Tipo de sonido por grabación
Licencia	ODC-By 1.0	CC BY 4.0	Libre acceso para investigación	MIT

2.3.1. CirCor DigiScope

La base CirCor DigiScope reúne grabaciones fonocardiográficas obtenidas durante dos campañas de tamizaje realizadas en el estado de Paraíba, Brasil, en 2014 y 2015, con un estetoscopio electrónico Littmann 3200 [10]. Cada paciente fue auscultado principalmente en cuatro focos, que corresponden a las válvulas aórtica, pulmonar, tricuspídea y mitral, por lo que tiene varias grabaciones asociadas. En este trabajo se utilizó la porción pública de la base, que corresponde al conjunto de entrenamiento del George B. Moody PhysioNet Challenge 2022 [9].

Las anotaciones se realizan por paciente. Para cada uno se indica si presenta un soplo, si no lo presenta o si la calidad de las grabaciones no permitió determinarlo. En los casos con soplo se agregan los focos en los que se escucha y sus características, descritas en la sección 2.1.1. Además, cada grabación incluye una segmentación del ciclo cardíaco, que marca el inicio y el fin de S1, de la sístole, de S2 y de la diástole.

2.3.2. SPRSound

SPRSound es una base de sonidos respiratorios pediátricos registrados con un estetoscopio digital Yunting modelo II en el *Shanghai Children's Medical Center*, un hospital pediátrico de China [12]. Su primera versión, publicada en 2022, contenía 2683 grabaciones de 292 pacientes. La base se amplió luego con las entregas de las ediciones 2023, 2024 y 2025 del desafío de sonidos respiratorios de la conferencia IEEE BioCAS. En este trabajo se utilizaron todas las entregas disponibles.

Cada grabación tiene dos niveles de anotación. A nivel de grabación se la clasifica como normal, con sonidos adventicios continuos, con sonidos adventicios discontinuos, con ambos tipos o de mala calidad. A nivel de evento se marcan el inicio y el fin de cada segmento y su tipo: normal, crepitante fino, crepitante grueso, sibilancia, roncus, estridor o sibilancia con crepitante. Las anotaciones fueron realizadas por un equipo de once médicos pediatras [12].

2.3.3. ICBHI 2017

La base del desafío ICBHI 2017 contiene grabaciones de sonidos respiratorios de pacientes de todas las edades, registradas en Portugal y en Grecia con cuatro equipos distintos, entre estetoscopios electrónicos y micrófonos [11]. Cada grabación se divide en ciclos respiratorios, y para cada ciclo se indica la presencia de crepitantes y de sibilancias. La base incluye además el diagnóstico de cada paciente. Predomina la enfermedad pulmonar obstructiva crónica, con 64 de los 126 pacientes, seguida por 26 pacientes sanos y 14 con infección del tracto respiratorio superior. Como se mencionó en la sección 1.3, es la referencia más utilizada para comparar algoritmos de clasificación de sonidos respiratorios.

2.3.4. HLS-CMDS

HLS-CMDS es una base grabada sobre un maniquí clínico que reproduce sonidos cardíacos y pulmonares, normales y patológicos, registrados con un estetoscopio digital en distintos puntos del tórax [21]. Contiene 50 grabaciones de sonidos cardíacos, 50 de sonidos pulmonares y 145 mezclas de ambos. Para cada mezcla se incluyen también sus dos componentes grabados por separado. Al no provenir de pacientes, sus sonidos son más controlados que los de una auscultación real, pero permiten evaluar el comportamiento de los modelos ante un equipo de grabación y unas condiciones que no forman parte del entrenamiento.

2.4. Modelo preentrenado

La transferencia de aprendizaje consiste en reutilizar una red entrenada sobre un conjunto de datos grande para resolver una tarea distinta, en la que los datos disponibles son menos. Las primeras capas de una red convolucional aprenden patrones generales de la señal, como bordes, texturas o componentes de frecuencia, que pueden aprovecharse en otros problemas. Existen dos formas habituales de aplicarla: utilizar la red preentrenada como extractor de características, con sus parámetros congelados, y entrenar solo un clasificador sobre ella, o bien utilizarla como punto de partida y ajustar una parte de sus parámetros con los datos de la nueva tarea, lo que se conoce como ajuste fino o *fine-tuning* [29].

En este trabajo se utilizó como modelo preentrenado la red CNN6 de la familia PANNs (*Pretrained Audio Neural Networks*) [29]. Las PANNs son redes entrenadas para el etiquetado de eventos sonoros sobre AudioSet, un conjunto de más de dos millones de fragmentos de audio de 10 s extraídos de videos de YouTube y etiquetados según una ontología de 527 clases, que incluye voz, música, sonidos de animales, sonidos ambientales y sonidos del cuerpo humano, entre otras [30]. Sus autores entrenaron las redes con unos 1,9 millones de esos fragmentos y publicaron los pesos resultantes, lo que permite utilizarlas como punto de partida en otras tareas de audio. La tabla 2.3 resume las características de la CNN6, la red convolucional más pequeña de la familia, que se eligió porque su tamaño resulta compatible con los recursos de cómputo descritos en la sección 2.2.

TABLA 2.3. Características del modelo preentrenado CNN6 de la familia PANNs [29].

Característica	**Valor**
Arquitectura	4 capas convolucionales de 5×5 con 64, 128, 256 y 512 filtros, cada una con normalización por lotes, ReLU y promedio de 2×2
Agregación y salida	Suma del promedio y el máximo global, capa de 512 unidades y salida de 527 clases
Parámetros	4,8 millones
Datos de preentrenamiento	AudioSet: 1,9 millones de fragmentos de 10 s, 527 clases
Entrada	Espectrograma log-Mel de 64 bandas entre 50 Hz y 14 kHz, calculado a 32 kHz con ventanas de 1024 muestras y saltos de 320
Aumentación en el preentrenamiento	*Mixup* y SpecAugment
Desempeño en AudioSet	Precisión media promedio (mAP) de 0,343

Los sonidos de AudioSet difieren de los de auscultación. Se trata de audio de uso general, muestreado a 32 kHz, mientras que las bases de entrenamiento de este trabajo están muestreadas a 4 y 8 kHz (tabla 2.2) y las alteraciones buscadas ocupan principalmente la parte baja del espectro, como se describió en la sección 2.1. Por lo tanto, para utilizar la CNN6 fue necesario adaptar la representación de entrada y la capa de salida a la tarea de este trabajo. El modo en que se realizó esa adaptación y el ajuste fino se describen en el capítulo 3.

Capítulo 3

Diseño e implementación

Capítulo 4

Ensayos y resultados

Capítulo 5

Conclusiones

Bibliografía

[1] Ariel Roguin. «Rene Theophile Hyacinthe Laënnec (1781–1826): The Man Behind the Stethoscope». En: *Clinical Medicine & Research* 4.3 (2006), págs. 230-235. DOI: 10.3121/cmr.4.3.230.

[2] Abraham Bohadana, Gabriel Izbicki y Steve S. Kraman. «Fundamentals of Lung Auscultation». En: *New England Journal of Medicine* 370.8 (2014), págs. 744-751. DOI: 10.1056/NEJMra1302901.

[3] Salvatore Mangione y Linda Z. Nieman. «Cardiac Auscultatory Skills of Internal Medicine and Family Practice Trainees: A Comparison of Diagnostic Proficiency». En: *JAMA* 278.9 (1997), págs. 717-722. DOI: 10.1001/jama.1997.03550090041030.

[4] Shuang Leng et al. «The Electronic Stethoscope». En: *BioMedical Engineering OnLine* 14.1 (2015), pág. 66. DOI: 10.1186/s12938-015-0056-y.

[5] World Health Organization. *Cardiovascular diseases (CVDs) – Fact sheet*. 2021. URL: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds) (visitado 25-10-2026).

[6] GBD Chronic Respiratory Disease Collaborators. «Prevalence and attributable health burden of chronic respiratory diseases, 1990–2017: a systematic analysis for the Global Burden of Disease Study 2017». En: *The Lancet Respiratory Medicine* 8.6 (2020), págs. 585-596. DOI: 10.1016/S2213-2600(20)30105-3.

[7] Organización Panamericana de la Salud. *PAHO warns of critical gaps in the health labor market in nine South American countries*. 2026. URL: https://www.paho.org/en/news/29-4-2026-paho-warns-critical-gaps-health-labor-market-nine-south-american-countries (visitado 25-10-2026).

[8] Gari D. Clifford et al. «Classification of Normal/Abnormal Heart Sound Recordings: the PhysioNet/Computing in Cardiology Challenge 2016». En: *2016 Computing in Cardiology Conference (CinC)*. Vol. 43. 2016. DOI: 10.22489/CinC.2016.179-154.

[9] Matthew A. Reyna et al. «Heart murmur detection from phonocardiogram recordings: The George B. Moody PhysioNet Challenge 2022». En: *PLOS Digital Health* 2.9 (2023), e0000324. DOI: 10.1371/journal.pdig.0000324.

[10] Jorge Oliveira et al. «The CirCor DigiScope Dataset: From Murmur Detection to Murmur Classification». En: *IEEE Journal of Biomedical and Health Informatics* 26.6 (2022), págs. 2524-2535. DOI: 10.1109/JBHI.2021.3137048.

[11] Bruno M. Rocha et al. «An open access database for the evaluation of respiratory sound classification algorithms». En: *Physiological Measurement* 40.3 (2019), pág. 035001. DOI: 10.1088/1361-6579/ab03ea.

[12] Qing Zhang et al. «SPRSound: Open-Source SJTU Paediatric Respiratory Sound Database». En: *IEEE Transactions on Biomedical Circuits and Systems* 16.5 (2022), págs. 867-881. DOI: 10.1109/TBCAS.2022.3204910.

[13] Zhao Ren et al. «A Comprehensive Survey on Heart Sound Analysis in the Deep Learning Era». En: *IEEE Computational Intelligence Magazine* 19.3 (2024), págs. 42-57. DOI: 10.1109/MCI.2024.3401309.

[14] Alyaa Hamel Sfayyih, Nasri Sulaiman y Ahmad H. Sabry. «A review on lung disease recognition by acoustic signal analysis with deep learning networks». En: *Journal of Big Data* 10 (2023), pág. 101. DOI: 10.1186/s40537-023-00762-z.

[15] Steven B. Davis y Paul Mermelstein. «Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences». En: *IEEE Transactions on Acoustics, Speech, and Signal Processing* 28.4 (1980), págs. 357-366. DOI: 10.1109/TASSP.1980.1163420.

[16] Cristhian Potes et al. «Ensemble of Feature-based and Deep learning-based Classifiers for Detection of Abnormal Heart Sounds». En: *2016 Computing in Cardiology Conference (CinC)*. Vol. 43. 2016. DOI: 10.22489/CinC.2016.182-399.

[17] Hui Lu et al. «A Lightweight Robust Approach for Automatic Heart Murmurs and Clinical Outcomes Classification from Phonocardiogram Recordings». En: *2022 Computing in Cardiology Conference (CinC)*. Vol. 49. 2022. DOI: 10.22489/CinC.2022.165.

[18] Siddhartha Gairola et al. «RespireNet: A Deep Neural Network for Accurately Detecting Abnormal Lung Sounds in Limited Data Setting». En: *2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*. 2021, págs. 527-530. DOI: 10.1109/EMBC46164.2021.9630091.

[19] Sangmin Bae et al. «Patch-Mix Contrastive Learning with Audio Spectrogram Transformer on Respiratory Sound Classification». En: *Proc. Interspeech 2023*. 2023, págs. 5436-5440. DOI: 10.21437/Interspeech.2023-1426.

[20] Zeenat Tariq, Sayed Khushal Shah y Yugyung Lee. «Feature-Based Fusion Using CNN for Lung and Heart Sound Classification». En: *Sensors* 22.4 (2022), pág. 1521. DOI: 10.3390/s22041521.

[21] Yasaman Torabi, Shahram Shirani y James P. Reilly. «Descriptor: Heart and Lung Sounds Dataset Recorded From a Clinical Manikin Using Digital Stethoscope (HLS-CMDS)». En: *IEEE Data Descriptions* 2 (2025), págs. 133-140. DOI: 10.1109/IEEEDATA.2025.3566012.

[22] Jennifer E. Frank y Kathryn M. Jacobe. «Evaluation and Management of Heart Murmurs in Children». En: *American Family Physician* 84.7 (2011), págs. 793-800. URL: https://www.aafp.org/pubs/afp/issues/2011/1001/p793.html.

[23] Anna-Leena Noponen et al. «Phono-spectrographic Analysis of Heart Murmur in Children». En: *BMC Pediatrics* 7 (2007), pág. 23. DOI: 10.1186/1471-2431-7-23.

[24] Malay Sarkar et al. «Auscultation of the Respiratory System». En: *Annals of Thoracic Medicine* 10.3 (2015), págs. 158-168. DOI: 10.4103/1817-1737.160831.

[25] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». En: *Advances in Neural Information Processing Systems*. Vol. 32. 2019. URL: https://arxiv.org/abs/1912.01703.

[26] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. 2015, págs. 18-25. DOI: 10.25080/Majora-7b98e3ed-003.

[27] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: https://www.jmlr.org/papers/v12/pedregosa11a.html.

[28] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt et al. «Array Programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362. DOI: 10.1038/s41586-020-2649-2.

[29] Qiuqiang Kong et al. «PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 28 (2020), págs. 2880-2894. DOI: 10.1109/TASLP.2020.3030497.

[30] Jort F. Gemmeke et al. «Audio Set: An Ontology and Human-Labeled Dataset for Audio Events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017, págs. 776-780. DOI: 10.1109/ICASSP.2017.7952261.