



Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación

Autor:

Ing. Santiago Federico Bettig

Director:

Dr. Ing. Leandro Javier Cymberknop (CIBIO, UTN FRBA)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 28 de abril de 2026 y el 16 de junio de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar.	5
1.1 Contexto del proyecto	5
1.2 Problema que se atiende	5
1.3 Estado del arte	5
1.4 Solución planteada y propuesta de valor	6
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	8
5. Supuestos del proyecto.	8
6. Product Backlog	9
7. Criterios de aceptación de historias de usuario	11
8. Fases de CRISP-DM	12
9. Desglose del trabajo en tareas	14
10. Planificación de Sprints	16
11. Diagrama de Gantt (sprints)	19
12. Gobernanza de datos	21
12.1 Cumplimiento normativo	21
12.2 Ética en el uso de la inteligencia artificial	21

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	28 de abril de 2026
1	Se completa hasta el punto 5 inclusive	09 de mayo de 2026
2	Se completa hasta el punto 9 inclusive	17 de mayo de 2026
3	Se completa hasta el punto 12 inclusive	23 de mayo de 2026

Acta de constitución del proyecto

Buenos Aires, 28 de abril de 2026

Por medio de la presente se acuerda con el Ing. Santiago Federico Bettig que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación” y consistirá en desarrollar un sistema de clasificación automática de patologías cardiopulmonares mediante redes neuronales convolucionales aplicadas a señales de auscultación. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de \$ 5.875.000, con fecha de inicio el 28 de abril de 2026 y fecha de presentación pública en diciembre de 2026.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Dr. Ing. Leandro Javier Cymberknop
CIBIO

Dr. Ing. Leandro Javier Cymberknop
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

1.1. Contexto del proyecto

Las enfermedades cardiovasculares y respiratorias representan dos de las principales causas de mortalidad a nivel mundial. Según la Organización Mundial de la Salud, las enfermedades cardíacas son responsables de aproximadamente 17 millones de muertes anuales, mientras que las enfermedades respiratorias afectan a más de 500 millones de personas. En ambos casos, el diagnóstico temprano es determinante para el pronóstico del paciente y para la reducción de costos en el sistema de salud. Sin embargo, acceder a ese diagnóstico es un desafío en gran parte del mundo.

1.2. Problema que se atiende

La auscultación con estetoscopio es una de las herramientas de diagnóstico más antiguas y vigentes de la medicina clínica. Permite detectar anomalías en los sonidos del corazón y los pulmones (soplos, arritmias, sibilancias, crepitantes) que son indicativas de patologías graves. Es una técnica no invasiva y de bajo costo. Un limitante del método es que su precisión depende, en gran medida, de la experiencia y el entrenamiento del profesional.

Esta limitación resulta crítica en regiones con escasez de especialistas, situación común en buena parte de América Latina. Usualmente, es el médico general quien debe interpretar los sonidos cardiopulmonares y decidir si derivar o no al paciente, sin contar con el criterio afinado de un cardiólogo o neumólogo. Esta brecha de acceso tiene consecuencias directas en la detección tardía de enfermedades tratables.

1.3. Estado del arte

En los últimos años, el aprendizaje profundo permitió desarrollar nuevas técnicas y aplicaciones para el análisis de señales biomédicas. La pandemia de COVID-19 aceleró el interés por herramientas de diagnóstico remoto y automatizado, impulsando el desarrollo de sistemas capaces de analizar sonidos respiratorios y cardíacos con alta precisión. Distintos desafíos públicos referentes al tema captaron la atención de equipos de todo el mundo, los cuales comenzaron a desarrollar algoritmos de clasificación y diagnóstico, generando una amplia literatura en la cual apoyarse.

Los enfoques más exitosos transforman las señales de audio en representaciones tiempo-frecuencia y las procesan con redes neuronales convolucionales (CNN), que aprenden automáticamente los patrones acústicos relevantes para cada patología. Algunos trabajos más recientes incorporan arquitecturas híbridas o mecanismos de atención que mejoran aún más la precisión. No obstante, la gran mayoría de estos sistemas aborda los sonidos cardíacos y pulmonares de forma aislada, como si fueran dominios independientes, cuando en la práctica clínica el médico los evalúa de manera integrada.

1.4. Solución planteada y propuesta de valor

Este trabajo propone desarrollar un sistema de clasificación automática de patologías cardiopulmonares que procese señales de auscultación mediante redes neuronales convolucionales, abordando conjuntamente los sonidos cardíacos y pulmonares en un único pipeline, como se observa en la figura 1. Esta integración representa el principal aporte diferencial respecto al estado del arte: la mayoría de los sistemas existentes tratan ambos dominios por separado, mientras que la auscultación clínica real no hace esa distinción.

El proyecto se enmarca en la Especialización en Inteligencia Artificial y se desarrolla en colaboración con el CIBIO (Centro de Investigación y Desarrollo en Ingeniería Biomédica) de la UTN Buenos Aires, bajo la dirección de Leandro Cymberknop. Los resultados serán de carácter académico y de acceso abierto, para que el CIBIO pueda incorporarlos en líneas de investigación clínica futuras.

El adoptante principal de esta solución es el médico general. Este perfil no necesita un sistema que reemplace su criterio clínico, sino uno que lo asista con una segunda opinión objetiva, reproducible y disponible en cualquier entorno donde haya un estetoscopio digital. La innovación pasa por facilitar el acceso a un nivel de análisis que hoy solo está disponible para quienes tienen acceso a especialistas. En términos del ciclo de vida, la solución se encuentra en etapa de investigación y prueba de concepto, con foco en la validación técnica del modelo sobre datasets públicos de referencia.




Figura 1. Diagrama en bloques del proyecto

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Dr. Ing. Leandro Javier Cymberknop	CIBIO	Director de CIBIO
Responsable	Ing. Santiago Federico Bettig	FIUBA	Alumno
Orientador	-	CIBIO, UTN FRBA	Participantes del grupo de investigación
Usuario final	-	-	Médicos generalistas y especialistas / Instituciones de salud / Usuarios potenciales del sistema de apoyo

- Responsable: el Ing. Santiago Federico Bettig es desarrollador de firmware hace más de 5 años, con experiencia en procesamiento digital de señales. Previamente trabajó en proyectos de aplicación en el campo de la medicina. Actualmente cursa la Carrera de Especialización en Inteligencia Artificial (CEIA).
- Cliente: el Dr. Ing. Leandro Javier Cymberknop es investigador categoría A en la UTN FRBA y director del grupo de investigación CIBIO. A lo largo de su carrera ha realizado numerosos posgrados relacionados con la medicina y la inteligencia artificial. También se desempeña como docente de la materia Análisis de Señales y Sistemas (ASyS) en la UTN FRBA.
- Orientador: CIBIO, Centro de Investigación y Desarrollo en Ingeniería Biomédica. El grupo está compuesto por investigadores capaces de asistir al responsable en el desarrollo del proyecto.

3. Propósito del proyecto

El propósito del proyecto es desarrollar una herramienta de apoyo al diagnóstico médico basada en inteligencia artificial, capaz de analizar y clasificar sonidos cardíacos y pulmonares obtenidos mediante un estetoscopio digital.

La iniciativa busca reducir la dependencia subjetiva del profesional a la interpretación de señales de auscultación, que ofrezca una segunda opinión objetiva y reproducible que pueda complementar la evaluación clínica. A diferencia de la mayoría de los sistemas existentes, que abordan los sonidos cardíacos y pulmonares de forma separada, este trabajo propone un enfoque integrado, más cercano a la práctica clínica real.

El proyecto es relevante en contextos con acceso limitado a especialistas, donde una herramienta de este tipo podría contribuir a mejorar la detección temprana de enfermedades y disminuir el tiempo en el que el paciente obtenga un diagnóstico certero.

Es importante mencionar que el proyecto busca ser una herramienta de apoyo para el profesional y este debe usarla para brindar el mejor diagnóstico posible. El resultado obtenido no deberá ser considerado como un diagnóstico final.

4. Alcance del proyecto

El proyecto incluye:

- La recopilación y preprocesamiento de datos de audio provenientes de datasets públicos.
- La extracción de features a partir de las señales de auscultación, mediante espectrogramas Mel y coeficientes MFCC.
- El diseño, entrenamiento y validación de un modelo de clasificación basado en redes neuronales convolucionales (CNN).
- La evaluación del rendimiento del modelo mediante métricas estándar (accuracy, F1-score, matriz de confusión).

El proyecto no incluye:

- El desarrollo de hardware ni la integración con un estetoscopio digital físico.
- La validación clínica del sistema con pacientes reales ni la obtención de aprobación regulatoria.
- El despliegue del modelo en un entorno de producción o aplicación médica real.
- La generación de un diagnóstico definitivo; el sistema actúa exclusivamente como herramienta de apoyo y no reemplaza el criterio del profesional de la salud.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- El responsable contará con el tiempo extralaboral suficiente para cumplir con el ciclo de vida del proyecto. Se deben tener en cuenta las responsabilidades y obligaciones extracurriculares.
- Se asume que se cuenta con los recursos económicos necesarios para llevar a cabo el proyecto, especificados previamente en el acta de constitución del proyecto.
- Los datasets serán accesibles y acordes para la realización del proyecto. No se espera que puedan utilizarse directamente, sino que se asume que debe trabajarse previamente sobre los mismos.
- Se contará con el equipo (hardware) acorde para el procesamiento de los datos y para la implementación del modelo final.
- Se supone que el director del Trabajo Final brindará orientación técnica y metodológica durante el desarrollo del proyecto, de acuerdo con su disponibilidad.
- En el caso de que el director no pueda responder las consultas por falta de conocimiento, se acudirá a la persona pertinente dentro del grupo de investigación

6. Product Backlog

- Épica 1: exploración y visualización preliminar de datos
 - HU1: Como desarrollador, quiero analizar la distribución de datos para identificar desbalances que deban corregirse antes del modelado.
 - Dificultad: 3, requiere familiarizarse con los datasets y las distintas estructuras.
 - Complejidad: 2, el análisis exploratorio es conceptualmente conocido, pero nunca lo apliqué a audio médico, por lo que tendrá su cuota de complejidad.
 - Incertidumbre: 5, no se sabe de antemano qué problemas de calidad o desbalances van a aparecer en los datos, lo que puede derivar en trabajo adicional no planificado.
 - Suma: 10 → 13 SP
 - HU2: como desarrollador, quiero visualizar señales de audio representativas de cada patología, para identificar diferencias relevantes entre clases y orientar el preprocesamiento de los datos.
 - Dificultad: 1, es accesible utilizando bibliotecas conocidas para realizar gráficos.
 - Complejidad: 1, no existen decisiones de diseño, ya se conoce el objetivo.
 - Incertidumbre: 2, a pesar de que existe incertidumbre por lo contaminado que puedan llegar a estar los audios, la literatura es abundante.
 - Suma: 4 → 5 SP
- Épica 2: Preprocesamiento de datos
 - HU3: como desarrollador, quiero normalizar y limpiar las señales de audio, para garantizar que los datos de entrada sean consistentes y libres de ruido.
 - Dificultad: 3, el preprocesamiento de audio médico requiere conocimiento específico sobre técnicas de eliminación de ruido y normalización aplicadas a señales fisiológicas.
 - Complejidad: 6, involucra múltiples subtarefas encadenadas (remuestreo, detección de ruido, normalización, validación) que realizarse para cumplir el objetivo principal de la tarea.
 - Incertidumbre: 5, la calidad real de las grabaciones es desconocida hasta abrirlas, y la elección de la técnica de eliminación de ruido más adecuada puede requerir experimentación iterativa.
 - Suma: 14 → 21 SP
 - HU4: como desarrollador, quiero extraer las features de cada grabación que me permitan alimentar el modelo.
 - Dificultad: 3, la extracción de espectrogramas Mel y coeficientes MFCC requiere comprensión profunda de los parámetros involucrados y su impacto en la representación del audio.
 - Complejidad: 6, el pipeline implica decisiones de diseño sobre distintos factores, los cuales influyen directamente sobre el modelo final.
 - Incertidumbre: 5, no conozco de antemano la configuración de parámetros que producirá el mejor resultado, lo que lleva a realizar gran cantidad de pruebas.
 - Suma: 14 → 21
- Épica 3: Desarrollo del modelo

- HU5: como desarrollador, quiero diseñar y entrenar un modelo, para clasificar automáticamente los sonidos cardíacos y pulmonares.
 - Dificultad: 3, se requieren conocimientos sobre la arquitectura y sobre detalles biomédicos.
 - Complejidad: 5, involucra decisiones de arquitectura, selección de función de pérdida, estrategia de entrenamiento y ajuste de hiperparámetros.
 - Incertidumbre: 6, el comportamiento del modelo no es predecible hasta experimentar. Es probable que los resultados preliminares obliguen a revisar parámetros/decisiones previas.
 - Suma: 14 → 21
- HU6: como desarrollador, quiero comparar el rendimiento del modelo sobre sonidos cardíacos y pulmonares por separado y de forma integrada, para determinar el mejor enfoque de clasificación.
 - Dificultad: 3, comparar modelos entrenados de forma separada versus integrada requiere un diseño experimental riguroso para que los resultados sean comparables y concluyentes.
 - Complejidad: 5, implica entrenar y evaluar múltiples variantes del modelo, analizar errores por tipo de patología y sintetizar conclusiones sobre el enfoque más efectivo.
 - Incertidumbre: 6, los resultados comparativos son completamente desconocidos hasta ejecutar los experimentos, y pueden surgir hallazgos inesperados que requieran iteraciones adicionales.
 - Suma: 14 → 21
- Épica 4: Evaluación
 - HU7: como desarrollador, quiero evaluar el modelo con métricas estándar (accuracy, F1-score, matriz de confusión), para conocer su capacidad de clasificación.
 - Dificultad: 2, calcular accuracy, F1-score, matriz de confusión y curva ROC es accesible con librerías estándar.
 - Complejidad: 3, la interpretación clínica de los resultados añade una capa de complejidad que va más allá del cálculo numérico.
 - Incertidumbre: 1, el proceso de evaluación está bien definido y es determinístico dado un modelo entrenado.
 - Suma: 6 → 8
 - HU8: como director, quiero revisar los resultados del modelo comparados con el estado del arte, para validar el aporte académico del trabajo.
 - Dificultad: 1, la búsqueda y síntesis bibliográfica es una tarea conocida en el ámbito académico.
 - Complejidad: 2, construir una tabla comparativa requiere seleccionar métricas homogéneas entre trabajos que pueden usar metodologías distintas, lo que agrega algo de complejidad.
 - Incertidumbre: 3, existe incertidumbre moderada sobre si los resultados propios serán comparables con los de la literatura, ya que depende del desempeño final del modelo, desconocido en esta etapa.
 - Suma: 6 → 8
- Épica 5: Documentación y cierre

- HU9: como desarrollador, quiero documentar todo el proceso y los resultados obtenidos, para presentar un trabajo final completo y reproducible.
 - Dificultad: 2, redactar documentación técnica requiere capacidad de síntesis y comunicación, no implica trabajo técnico nuevo.
 - Complejidad: 3, integrar todas las etapas del proyecto en un informe coherente, con código comentado y un README completo, tiene una complejidad moderada.
 - Incertidumbre: 1, documenta trabajo ya realizado, por lo que la incertidumbre es prácticamente nula.
 - Suma: 6 → 8
- HU10: como director, quiero contar con un informe final claro y bien estructurado, para poder evaluar el trabajo y certificar su aprobación.
 - Dificultad: 2, la redacción del informe final sigue los lineamientos formales de la especialización, los cuales están definidos de antemano.
 - Complejidad: 4, el informe debe integrar resultados técnicos, análisis crítico, conclusiones y trabajo futuro en un documento que cumpla estándares académicos y sea validado por el director.
 - Incertidumbre: 3, existe incertidumbre sobre la cantidad de revisiones y correcciones que el director solicitará, y sobre el tiempo que tomará incorporarlas antes de la defensa.
 - Suma: 9 → 13

7. Criterios de aceptación de historias de usuario

■ Épica 1:

- Criterios de aceptación HU1
 - Se generan gráficos de distribución de cada clase.
 - Se identifica y documenta cada una de las clases.
 - Se propone una estrategia de balanceo basada en los resultados.
- Criterios de aceptación HU2
 - Se grafican múltiples señales en dominio temporal por cada clase.
 - Se grafican múltiples señales en dominio de la frecuencia.
 - Se realiza la visualización y análisis para su inclusión posterior en el informe final.

■ Épica 2:

- Criterios de aceptación HU3
 - Se remuestrean todas las grabaciones a una tasa normalizada que será común a todas las grabaciones.
 - Se eliminan los segmentos con ruido excesivo.
 - Se normaliza la amplitud de todas las señales.
- Criterios de aceptación HU4
 - Se generan espectrogramas Mel y vectores MFCC para todas las grabaciones.
 - Se almacenan los features en un formato utilizable.

- Se documenta la configuración de parámetros utilizada.
- Épica 3:
 - Criterios de aceptación HU5
 - Se realiza una investigación para conocer qué modelo aplica mejor para el proyecto.
 - Asegurarse que el modelo converja durante el entrenamiento.
 - Se debe alcanzar un resultado razonable sobre el conjunto de validación.
 - Criterios de aceptación HU6
 - Se entrena y evalúa el modelo de forma separada y de forma integrada para cada tipo de sonido.
 - Los resultados de cada variante serán documentados y comparados en una tabla.
 - Se elabora una conclusión sobre cuál enfoque resulta más efectivo.
- Épica 4:
 - Criterios de aceptación HU7
 - Se reportan accuracy, F1-score por clase, matriz de confusión y curva ROC sobre el conjunto de prueba.
 - Se realiza una representación de los datos acorde.
 - Se realiza la interpretación de los datos en el contexto clínico del problema.
 - Criterios de aceptación HU8
 - Se incluye una tabla comparativa con otros trabajos relevantes de la literatura.
 - Se identifican los aspectos en que el trabajo supera, iguala o queda por debajo del estado del arte.
 - Se elabora una reflexión sobre el aporte original del trabajo en relación a la literatura existente.
- Épica 5:
 - Criterios de aceptación HU9
 - Desarrollar un informe final que cubra todas las etapas del proyecto.
 - Que el código quede correctamente comentado para desarrollos complementarios.
 - Que se revise y apruebe el informe por el director de proyecto.
 - Criterios de aceptación HU10
 - Que se cumplan con los requisitos formales de la especialización y sea revisado por el CIBIO.
 - Que el director apruebe el informe previo a la defensa del trabajo.
 - Que se incluyan conclusiones claras y una sección de trabajo futuro.

8. Fases de CRISP-DM

1. Comprensión del negocio:

- Entender el problema desde el punto de vista clínico y definir los objetivos del proyecto.
- Revisar literatura sobre auscultación y diagnóstico asistido por IA.

- Definir el problema como un clasificador y establecer las métricas adecuadas para su evaluación.

2. Comprensión de los datos:

- Se trabajará con sonidos obtenidos por medio de un estetoscopio digital. Se deben analizar los mismos para detectar problemas de calidad en las grabaciones.
- Además, se espera obtener gráficas que representen a cada una de las clases (tanto en frecuencia como en tiempo).

3. Preparación de los datos:

- Normalización y limpieza de las señales.
- Extracción de features.
- División del dataset en conjuntos de entrenamiento, validación y prueba.
- Si es necesario, la aumentación de los datos para corregir el desbalance de clases.

4. Modelado:

- Diseño, optimización y evaluación del modelo.
- Comparación entre enfoque integrado y los modelos entrenados por separado.

5. Evaluación del modelo:

- Se obtendrán métricas para evaluar el desempeño del modelo.
- Se analizarán los errores que cometa el modelo.
- Se validarán los resultados con el CIBIO.

9. Desglose del trabajo en tareas

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU1	Investigar y documentar el estado del arte	5 h	Media
HU1	Cargar datasets y realizar un análisis exploratorio de los datos	6 h	Alta
HU1	Análisis de calidad de las grabaciones (duración, frecuencia de muestreo, formato)	6 h	Alta
HU1	Documentar los hallazgos e identificar una estrategia de balanceo	8 h	Alta
HU2	Graficar la forma de onda temporal de la clases representativas	5 h	Media
HU2	Generar representaciones en frecuencia de cada clase y comparar visualmente	6 h	Media
HU3	Remuestrear todas las grabaciones a una frecuencia de muestreo común	8 h	Alta
HU3	Normalizar la amplitud de cada señal y marcar los segmentos con ruido excesivo	8 h	Alta
HU3	Investigar y comparar técnicas de eliminación de ruido	8 h	Alta
HU3	Eliminar ruido excesivo en los segmentos marcados	7 h	Alta
HU3	Validar visualmente los resultados del preprocesamiento comparando señales antes y después	8 h	Media
HU4	Investigar y comparar parámetros óptimos para espectrogramas Mel y MFCC	8 h	Alta
HU4	Implementar pipeline para la extracción de datos	8 h	Alta
HU4	Experimentar con distintas configuraciones de ventana y número de coeficientes	8 h	Media
HU4	Validar la calidad de los features generados	7 h	Alta

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU4	Almacenar los features generados en un formato acorde y documentar lo realizado	7 h	Alta
HU5	Investigar arquitecturas CNN aplicadas a clasificación de audio médico	7 h	Alta
HU5	Implementar al menos dos arquitecturas candidatas y comparar	8 h	Alta
HU5	Definir y documentar la arquitectura del modelo	8 h	Alta
HU5	Entrenar modelo y ajustar hiperparámetros	8 h	Alta
HU6	Realizar análisis de errores por tipo de patología para cada variante	8 h	Alta
HU6	Entrenar y ajustar modelos cardíacos y pulmonares por separados	8 h	Alta
HU6	Construir una tabla comparativa y analizar los resultados	5 h	Media
HU6	Documentar conclusiones sobre el enfoque integrado vs separado	7 h	Media
HU7	Calcular accuracy, F1-score por clase, matriz de confusión y curva ROC sobre el conjunto de prueba	4 h	Alta
HU7	Generar visualizaciones de cada métrica.	5 h	Media
HU7	Interpretar resultados en contexto clínico junto al equipo del CIBIO	4 h	Media
HU7	Optimizar modelo luego de obtener los resultados preliminares	8 h	Alta
HU8	Seleccionar trabajos relevantes de la literatura y extraer métricas principales	6 h	Baja
HU8	Construir una tabla comparativa e identificar el aporte diferencial del trabajo	4 h	Baja
HU8	Redactar análisis crítico del aporte diferencial del trabajo	7 h	Baja
HU9	Redactar el informe final hasta cubrir todas las etapas del pipeline	8 h	Alta
HU9	Revisar el informe junto al director e incorporar las correcciones antes de la entrega	6 h	Media

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU10	Preparar presentación para la defensa	8 h	Media
HU10	Verificar que el informe cumple los requisitos formales de la especialización	4 h	Media
HU10	Incorporar una sección de conclusiones y trabajo futuro basada en los resultados obtenidos	3 h	Baja

10. Planificación de Sprints

Sprint	HU o fase	Tarea	Horas / SP	Responsable	% Completado
Sprint 0	Planificación	Redacción del plan de proyecto (1er versión)	6 h / 3 SP	Alumno	100 %
Sprint 0	Planificación	Redacción del plan de proyecto (2da versión)	6 h / 3 SP	Alumno	100 %
Sprint 0	HU1	Investigar y documentar el estado del arte	6 h / 3 SP	Alumno	25 %
Sprint 1	Planificación	Redacción del plan de proyecto (3da versión)	6 h / 3 SP	Alumno	25 %
Sprint 1	Planificación	Redacción del plan de proyecto (4ta versión)	6 h / 3 SP	Alumno	0 %
Sprint 1	HU1	Cargar datasets y análisis exploratorio	6 h / 3 SP	Alumno	0 %
Sprint 2	Planificación	Confeción presentación de plan	5 h / 3 SP	Alumno	0 %
Sprint 2	HU1	Análisis de calidad de las grabaciones	6 h / 3 SP	Alumno	0 %
Sprint 2	HU1	Documentar hallazgos e identificar estrategia de balanceo	8 h / 4 SP	Alumno	0 %

Sprint	HU o fase	Tarea	Horas / SP	Responsable	% Completado
Sprint 3	HU2	Graficar forma de onda temporal por clase	6 h / 3 SP	Alumno	0 %
Sprint 3	HU2	Generar representaciones en frecuencia y comparar	6 h / 3 SP	Alumno	0 %
Sprint 3	Seguimiento	Reunión de seguimiento con el CIBIO	2 h / 1 SP	Alumno	0 %
Sprint 4	HU3	Investigar técnicas de eliminación de ruido	8 h / 4 SP	Alumno	0 %
Sprint 4	HU3	Remuestrear grabaciones a frecuencia común	8 h / 4 SP	Alumno	0 %
Sprint 4	HU3	Normalizar amplitud y marcar segmentos con ruido	8 h / 4 SP	Alumno	0 %
Sprint 5	Documentación	Documentación: exploración y datos	4 h / 2 SP	Alumno	0 %
Sprint 5	HU3	Eliminar ruido excesivo en segmentos marcados	8 h / 4 SP	Alumno	0 %
Sprint 5	HU3	Validar resultados del preprocesamiento antes/después	8 h / 4 SP	Alumno	0 %
Sprint 5	Seguimiento	Reunión de seguimiento con el CIBIO	2 h / 1 SP	Alumno	0 %
Sprint 6	HU4	Investigar parámetros óptimos para Mel y MFCC	8 h / 4 SP	Alumno	0 %
Sprint 6	HU4	Implementar pipeline de extracción de features	8 h / 4 SP	Alumno	0 %
Sprint 6	Documentación	Documentar preprocesamiento	4 h / 2 SP	Alumno	0 %

Sprint	HU o fase	Tarea	Horas / SP	Responsable	% Completado
Sprint 7	HU4	Experimentar con configuraciones y validar features	8 h / 4 SP	Alumno	0 %
Sprint 7	HU4	Almacenar features y documentar configuración	8 h / 4 SP	Alumno	0 %
Sprint 7	Seguimiento	Reunión de seguimiento con el CIBIO	2 h / 1 SP	Alumno	0 %
Sprint 8	HU5	Investigar mejores modelos para procesamiento	8 h / 4 SP	Alumno	0 %
Sprint 8	HU5	Implementar arquitecturas candidatas y comparar	8 h / 4 SP	Alumno	0 %
Sprint 8	Documentación	Documentar arquitecturas y features	4 h / 2 SP	Alumno	0 %
Sprint 9	HU5	Definir, documentar y entrenar arquitectura final	16 h / 8 SP	Alumno	0 %
Sprint 9	HU6	Entrenar modelos cardíacos y pulmonares por separado	8 h / 4 SP	Alumno	0 %
Sprint 9	Seguimiento	Reunión de seguimiento con el CIBIO	2 h / 1 SP	Alumno	0 %
Sprint 10	HU6	Análisis de errores por patología	8 h / 4 SP	Alumno	0 %
Sprint 10	HU6	Confección de tabla comparativa	4 h / 2 SP	Alumno	0 %
Sprint 10	HU7	Optimizar modelo en base a resultados obtenidos	20 h / 10 SP	Alumno	0 %

Sprint	HU o fase	Tarea	Horas / SP	Responsable	% Completado
Sprint 10	Documentación	Documentar modelado y análisis comparativo	2 h / 1 SP	Alumno	0 %
Sprint 11	HU7	Calcular métricas finales, visualizaciones e interpretación clínica	8 h / 4 SP	Alumno	0 %
Sprint 11	HU8	Comparativa entre estado del arte y resultados obtenidos	4 h / 2 SP	Alumno	0 %
Sprint 11	Documentación	Evaluación y comparativa	4 h / 2 SP	Alumno	0 %
Sprint 12	Redacción	Confección de memoria técnica (Parte 1)	20 h / 10 SP	Alumno	0 %
Sprint 13	Redacción	Confección de memoria técnica (Parte 2)	20 h / 10 SP	Alumno	0 %
Sprint 14	Redacción	Confección de memoria técnica (Parte 3)	20 h / 10 SP	Alumno	0 %
Sprint 15	Redacción	Confección de memoria técnica (Parte 4)	20 h / 10 SP	Alumno	0 %

11. Diagrama de Gantt (sprints)




Figura 2. Diagrama de Gantt del proyecto

12. Gobernanza de datos

12.1. Cumplimiento normativo

Los datos utilizados en este proyecto provienen de datasets públicos de acceso abierto, los cuales fueron distribuidos libremente para investigación y uso académico. Ambos datasets fueron recolectados por sus autores originales, quienes son responsables del cumplimiento normativo en la dicha etapa. En consecuencia, el presente proyecto no involucra recolección de datos de pacientes reales ni acceso a información clínica sensible.

No obstante, dado el carácter biomédico de los datos, corresponde considerar el marco normativo aplicable:

- En el plano internacional, el Reglamento General de Protección de Datos (GDPR) de la Unión Europea establece requisitos estrictos para el tratamiento de datos de salud clasificados como datos sensibles. Si bien el proyecto se desarrolla en Argentina y los datos son anónimos, el GDPR es un marco de referencia relevante dado que los datasets provienen de instituciones europeas. En este contexto, el proyecto cumple con sus principios al utilizar datos anónimos, con fines exclusivamente académicos y sin posibilidad de identificación de individuos.
- En el plano local, la Ley 25.326 de Protección de los Datos Personales de Argentina regula el tratamiento de datos personales, incluyendo los datos de salud como categoría protegida. Dado que los datos utilizados no contienen información que permita identificar a personas físicas, el proyecto se encuadra dentro de los usos permitidos por esta normativa.
- En cuanto a la propiedad intelectual, los entregables del proyecto son de carácter académico y de acceso abierto, en línea con lo establecido en el acta de constitución del proyecto. Se respetan las licencias de los datasets originales, que permiten su uso para investigación sin fines comerciales.

12.2. Ética en el uso de la inteligencia artificial

El desarrollo de sistemas de inteligencia artificial aplicados a la medicina plantea consideraciones éticas que van más allá del cumplimiento normativo estricto. Este proyecto adhiere a los principios éticos establecidos por organismos internacionales de referencia, como la UNESCO en su Recomendación sobre la Ética de la Inteligencia Artificial (2021) y las guías de la Organización Mundial de la Salud (OMS) para el uso de IA en salud (2021).

Los principios éticos que guían el desarrollo de este trabajo son los siguientes:

- Beneficencia y no maleficencia: el sistema está diseñado exclusivamente como herramienta de apoyo al diagnóstico médico. Sus resultados no deben ser interpretados como un diagnóstico definitivo ni reemplazar el criterio clínico del profesional de la salud. Esta limitación está explícitamente incorporada en el propósito y el alcance del proyecto, y deberá ser claramente comunicada en cualquier instancia de uso o difusión del sistema.
- Transparencia y explicabilidad: el modelo y su proceso de desarrollo serán documentados de forma completa y reproducible, permitiendo que otros investigadores puedan auditar, replicar y cuestionar los resultados.

- Equidad y no discriminación: los datasets utilizados presentan limitaciones en cuanto a la diversidad de la población representada. Esta limitación será documentada explícitamente y deberá considerarse al momento de evaluar la generalización del modelo a otras poblaciones o contextos clínicos.
- Responsabilidad: el responsable del proyecto asume la obligación de garantizar que los resultados sean presentados con rigor académico, sin exagerar las capacidades del sistema ni minimizar sus limitaciones.
- Privacidad y protección de datos: aunque los datos utilizados son públicos y anónimos, el proyecto adopta como principio general el tratamiento mínimo y necesario de los datos, evitando cualquier procesamiento que no sea estrictamente requerido para los objetivos del trabajo.