



Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación

Autor:

Ing. Santiago Federico Bettig

Director:

Dr. Ing. Leandro Javier Cymberknop (CIBIO, UTN FRBA)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 28 de abril de 2026 y el 16 de junio de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar.	5
1.1 Contexto del proyecto	5
1.2 Problema que se atiende	5
1.3 Estado del arte	5
1.4 Solución planteada y propuesta de valor	6
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	8
5. Supuestos del proyecto.	8
6. Product Backlog	9
7. Criterios de aceptación de historias de usuario	10
8. Fases de CRISP-DM	12
9. Desglose del trabajo en tareas	13
10. Planificación de Sprints	14

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	28 de abril de 2026
1	Se completa hasta el punto 5 inclusive	09 de mayo de 2026
2	Se completa hasta el punto 9 inclusive	17 de mayo de 2026

Acta de constitución del proyecto

Buenos Aires, 28 de abril de 2026

Por medio de la presente se acuerda con el Ing. Santiago Federico Bettig que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Detección de patologías cardiopulmonares mediante redes neuronales aplicadas a señales de auscultación” y consistirá en desarrollar un sistema de clasificación automática de patologías cardiopulmonares mediante redes neuronales convolucionales aplicadas a señales de auscultación. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de \$ 5.875.000, con fecha de inicio el 28 de abril de 2026 y fecha de presentación pública en diciembre de 2026.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Dr. Ing. Leandro Javier Cymberknop
CIBIO

Dr. Ing. Leandro Javier Cymberknop
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

1.1. Contexto del proyecto

Las enfermedades cardiovasculares y respiratorias representan dos de las principales causas de mortalidad a nivel mundial. Según la Organización Mundial de la Salud, las enfermedades cardíacas son responsables de aproximadamente 17 millones de muertes anuales, mientras que las enfermedades respiratorias afectan a más de 500 millones de personas. En ambos casos, el diagnóstico temprano es determinante para el pronóstico del paciente y para la reducción de costos en el sistema de salud. Sin embargo, acceder a ese diagnóstico **es** un desafío en gran parte del mundo.

1.2. Problema que se atiende

La auscultación con estetoscopio es una de las herramientas de diagnóstico más antiguas y vigentes de la medicina clínica. Permite detectar anomalías en los sonidos del corazón y los pulmones (soplos, arritmias, sibilancias, crepitantes) que son indicativas de patologías graves. Es una técnica no invasiva y de bajo costo. Un limitante del método es que su precisión depende, en gran medida, de la experiencia y el entrenamiento del profesional.

Esta limitación **resulta** crítica en regiones con escasez de especialistas, situación común en buena parte de América Latina. Usualmente, es el médico general quien debe interpretar los sonidos cardiopulmonares y decidir si derivar o no al paciente, sin contar con el criterio afinado de un cardiólogo o neumólogo. Esta brecha de acceso tiene consecuencias directas en la detección tardía de enfermedades tratables.

1.3. Estado del arte

En los últimos años, el aprendizaje profundo permitió desarrollar nuevas técnicas y aplicaciones para el análisis de señales biomédicas. La pandemia de COVID-19 aceleró el interés por herramientas de diagnóstico remoto y automatizado, impulsando el desarrollo de sistemas capaces de analizar sonidos respiratorios y cardíacos con alta precisión. Distintos desafíos públicos referentes al tema captaron la atención de equipos de todo el mundo, los cuales comenzaron a desarrollar algoritmos de clasificación y diagnóstico, generando una amplia literatura en la cual apoyarse.

Los enfoques más exitosos transforman las señales de audio en representaciones tiempo-frecuencia y las procesan con redes neuronales convolucionales (CNN), que aprenden automáticamente los patrones acústicos relevantes para cada patología. Algunos trabajos más recientes incorporan arquitecturas híbridas o mecanismos de atención que mejoran aún más la precisión. No obstante, la gran mayoría de estos sistemas aborda los sonidos cardíacos y pulmonares de forma aislada, como si fueran dominios independientes, cuando en la práctica clínica el médico los evalúa de manera integrada.

1.4. Solución planteada y propuesta de valor

Este trabajo propone desarrollar un sistema de clasificación automática de patologías cardiopulmonares que procese señales de auscultación mediante redes neuronales convolucionales, abordando conjuntamente los sonidos cardíacos y pulmonares en un único pipeline (Ver Fig. 1). Esta integración representa el principal aporte diferencial respecto al estado del arte: la mayoría de los sistemas existentes tratan ambos dominios por separado, mientras que la auscultación clínica real no hace esa distinción.

El proyecto se enmarca en la Especialización en Inteligencia Artificial y se desarrolla en colaboración con el CIBIO (Centro de Investigación y Desarrollo en Ingeniería Biomédica) de la UTN Buenos Aires, bajo la dirección de Leandro Cymberknop. Los resultados serán de carácter académico y de acceso abierto, para que el CIBIO pueda incorporarlos en líneas de investigación clínica futuras.

El adoptante principal de esta solución es el médico general. Este perfil no necesita un sistema que reemplace su criterio clínico, sino uno que lo asista con una segunda opinión objetiva, reproducible y disponible en cualquier entorno donde haya un estetoscopio digital. La innovación pasa por facilitar el acceso a un nivel de análisis que hoy solo está disponible para quienes tienen acceso a especialistas. En términos del ciclo de vida, la solución se encuentra en etapa de investigación y prueba de concepto, con foco en la validación técnica del modelo sobre datasets públicos de referencia.




Figura 1. Diagrama en bloques del proyecto

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Dr. Ing. Leandro Javier Cymberknop	CIBIO	Director de CIBIO
Responsable	Ing. Santiago Federico Bettig	FIUBA	Alumno
Orientador	-	CIBIO, UTN FRBA	Participantes del grupo de investigación
Usuario final	-	-	Médicos generalistas y especialistas / Instituciones de salud / Usuarios potenciales del sistema de apoyo

- Responsable: el Ing. Santiago Federico Bettig es desarrollador de firmware hace más de 5 años, con experiencia en procesamiento digital de señales. Previamente trabajó en proyectos de aplicación en el campo de la medicina. Actualmente cursa la Carrera de Especialización en Inteligencia Artificial (CEIA).
- Cliente: el Dr. Ing. Leandro Javier Cymberknop es investigador categoría A en la UTN FRBA y director del grupo de investigación CIBIO. A lo largo de su carrera ha realizado numerosos posgrados relacionados con la medicina y la inteligencia artificial. También se desempeña como docente de la materia Análisis de Señales y Sistemas (ASyS) en la UTN FRBA.
- Orientador: CIBIO, Centro de Investigación y Desarrollo en Ingeniería Biomédica. El grupo está compuesto por investigadores capaces de asistir al responsable en el desarrollo del proyecto.

3. Propósito del proyecto

El propósito del proyecto es desarrollar una herramienta de apoyo al diagnóstico médico basada en inteligencia artificial, capaz de analizar y clasificar sonidos cardíacos y pulmonares obtenidos mediante un estetoscopio digital.

La iniciativa busca reducir la dependencia subjetiva del profesional en la interpretación de señales de auscultación, que ofrezca una segunda opinión objetiva y reproducible que pueda complementar la evaluación clínica. A diferencia de la mayoría de los sistemas existentes, que abordan los sonidos cardíacos y pulmonares de forma separada, este trabajo propone un enfoque integrado, más cercano a la práctica clínica real.

El proyecto es relevante en contextos con acceso limitado a especialistas, donde una herramienta de este tipo podría contribuir a mejorar la detección temprana de enfermedades y disminuir el tiempo en el que el paciente obtenga un diagnóstico certero.

Es importante mencionar que el proyecto busca ser una herramienta de apoyo para el profesional y este debe usarla para brindar el mejor diagnóstico posible. El resultado obtenido no deberá ser considerado como un diagnóstico final.

4. Alcance del proyecto

El proyecto incluye:

- La recopilación y preprocesamiento de datos de audio provenientes de datasets públicos.
- La extracción de features a partir de las señales de auscultación, mediante espectrogramas Mel y coeficientes MFCC.
- El diseño, entrenamiento y validación de un modelo de clasificación basado en redes neuronales convolucionales (CNN).
- La evaluación del rendimiento del modelo mediante métricas estándar (accuracy, F1-score, matriz de confusión).

El proyecto no incluye:

- El desarrollo de hardware ni la integración con un estetoscopio digital físico.
- La validación clínica del sistema con pacientes reales ni la obtención de aprobación regulatoria.
- El despliegue del modelo en un entorno de producción o aplicación médica real.
- La generación de un diagnóstico definitivo; el sistema actúa exclusivamente como herramienta de apoyo y no reemplaza el criterio del profesional de la salud.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- El responsable contará con el tiempo extralaboral suficiente para cumplir con el ciclo de vida del proyecto. Se debe tener en cuenta las responsabilidades y obligaciones extracurriculares.
- Se asume que se cuenta con los recursos económicos necesarios para llevar a cabo el proyecto, especificados previamente en el acta de constitución del proyecto.
- Los datasets serán accesibles y acordes para la realización del proyecto. No se espera que puedan utilizarse directamente, sino que se asume que debe trabajarse previamente sobre los mismos.
- Se contará con el equipo (hardware) acorde para el procesamiento de los datos y para la implementación del modelo final.
- Se supone que el director del Trabajo Final brindará orientación técnica y metodológica durante el desarrollo del proyecto, de acuerdo con su disponibilidad.
- En el caso de que el director no pueda responder las consultas por falta de conocimiento, se acudirá a la persona pertinente dentro del grupo de investigación

6. Product Backlog

- **Épica 1: Exploración y visualización preliminar de datos**
 - HU1: Como desarrollador, quiero analizar la distribución de datos para identificar desbalances que deban corregirse antes del modelado.
 - Dificultad: 3
 - Complejidad: 2
 - Incertidumbre: 2
 - Suma: 7 → 8
 - HU2: Como desarrollador, quiero visualizar señales de audio representativas de cada patología, para adquirir la habilidad de detectar diferencias entre clases.
 - Dificultad: 1
 - Complejidad: 1
 - Incertidumbre: 1
 - Suma: 3 → 3
- **Épica 2: Preprocesamiento de datos**
 - HU3: Como desarrollador, quiero normalizar y limpiar las señales de audio, para garantizar que los datos de entrada sean consistentes y libres de ruido.
 - Dificultad: 3
 - Complejidad: 5
 - Incertidumbre: 1
 - Suma: 9 → 13
 - HU4: Como desarrollador, quiero extraer las features de cada grabación que me permitan alimentar el modelo.
 - Dificultad: 2
 - Complejidad: 5
 - Incertidumbre: 2
 - Suma: 9 → 13
- **Épica 3: Desarrollo del modelo**
 - HU5: Como desarrollador, quiero diseñar y entrenar un modelo, para clasificar automáticamente los sonidos cardíacos y pulmonares.
 - Dificultad: 3
 - Complejidad: 5
 - Incertidumbre: 5
 - Suma: 13 → 13
 - HU6: Como desarrollador, quiero comparar el rendimiento del modelo sobre sonidos cardíacos y pulmonares por separado y de forma integrada, para determinar el mejor enfoque de clasificación.
 - Dificultad: 3
 - Complejidad: 5
 - Incertidumbre: 5
 - Suma: 13 → 13

■ Épica 4: Evaluación

- HU7: Como desarrollador, quiero evaluar el modelo con métricas estándar (accuracy, F1-score, matriz de confusión), para conocer su capacidad de clasificación.
 - Dificultad: 2
 - Complejidad: 2
 - Incertidumbre: 1
 - Suma: 5 → 5
- HU8: Como director, quiero revisar los resultados del modelo comparados con el estado del arte, para validar el aporte académico del trabajo.
 - Dificultad: 1
 - Complejidad: 1
 - Incertidumbre: 2
 - Suma: 4 → 5

■ Épica 5: Documentación y cierre

- HU9: Como desarrollador, quiero documentar todo el proceso y los resultados obtenidos, para presentar un trabajo final completo y reproducible.
 - Dificultad: 2
 - Complejidad: 3
 - Incertidumbre: 1
 - Suma: 6 → 8
- HU10: Como director, quiero contar con un informe final claro y bien estructurado, para poder evaluar el trabajo y certificar su aprobación.
 - Dificultad: 1
 - Complejidad: 3
 - Incertidumbre: 2
 - Suma: 6 → 8

7. Criterios de aceptación de historias de usuario

■ Épica 1:

● Criterios de aceptación HU1

- Se generan gráficos de distribución de cada clase.
- Se identifica y documenta cada una de las clases.
- Se propone una estrategia de balanceo basada en los resultados.

● Criterios de aceptación HU2

- Se grafican múltiples señales en dominio temporal por cada clase.
- Se grafican múltiples señales en dominio de la frecuencia.
- Se realiza la visualización y análisis para su inclusión posterior en el informe final.

■ Épica 2:

● Criterios de aceptación HU3

- Se remuestrean todas las grabaciones a una tasa normalizada que será común a todas las grabaciones.
 - Se eliminan los segmentos con ruido excesivo.
 - Se normaliza la amplitud de todas las señales.
 - Criterios de aceptación HU4
 - Se generan espectrogramas Mel y vectores MFCC para todas las grabaciones.
 - Se almacenan los features en un formato utilizable.
 - Se documenta la configuración de parámetros utilizada.
- Épica 3:
 - Criterios de aceptación HU5
 - Realizar una investigación para conocer que modelo aplica mejor para el proyecto.
 - Asegurarse que el modelo converga durante el entrenamiento.
 - Se debe alcanzar un resultado razonable sobre el conjunto de validación.
 - Criterios de aceptación HU6
 - Se entrena y evalúa el modelo de forma separada y de forma integrada para cada tipo de sonido.
 - Los resultados de cada variante serán documentados y comparados en una tabla.
 - Se elabora una conclusión sobre cuál enfoque resulta más efectivo.
- Épica 4:
 - Criterios de aceptación HU7
 - Se reportan accuracy, F1-score por clase, matriz de confusión y curva ROC sobre el conjunto de prueba.
 - Se realiza una representación de los datos acorde.
 - Se realiza la interpretación de los datos en el contexto clínico del problema.
 - Criterios de aceptación HU8
 - Se incluye una tabla comparativa con otros trabajos relevantes de la literatura.
 - Se identifican los aspectos en que el trabajo supera, iguala o queda por debajo del estado del arte.
 - Se elabora una reflexión sobre el aporte original del trabajo en relación a la literatura existente.
- Épica 5:
 - Criterios de aceptación HU9
 - Desarrollar un informe final que cubra todas las etapas del proyecto.
 - Que el código quede correctamente comentado para desarrollos complementarios.
 - Que se revise y apruebe el informe por el director de proyecto.
 - Criterios de aceptación HU10
 - Que se cumplan con los requisitos formales de la especialización y sea revisado por el CIBIO.
 - Que el director apruebe el informe previo a la defensa del trabajo.
 - Que se incluyan conclusiones claras y una sección de trabajo futuro.

8. Fases de CRISP-DM

1. Comprensión del negocio:

- Entender el problema desde el punto de vista clínico y definir los objetivos del proyecto.
- Revisar literatura sobre auscultación y diagnóstico asistido por IA.
- Definir el problema como un clasificador y establecer las métricas adecuadas para su evaluación.

2. Comprensión de los datos:

- Se trabajara con sonidos obtenidos utilizando un estetoscopio digital. Se deben analizar los mismos para detectar problemas de calidad en las grabaciones.
- Además, se espera obtener gráficas que representan a cada una de las clases (tanto en frecuencia como en tiempo)

3. Preparación de los datos:

- Normalización y limpieza de las señales.
- Extracción de features.
- División del dataset en conjuntos de entrenamiento, validación y prueba.
- Si es necesario, la aumentación de los datos para corregir el desbalance de clases.

4. Modelado:

- Diseño, optimización y evaluación del modelo.
- Comparación entre enfoque integrado y los modelos entrenados por separado.

5. Evaluación del modelo:

- Se obtendrán métricas para evaluar el desempeño del modelo
- Se analizarán los errores que cometa el modelo
- Se validarán los resultados con el CIBIO

9. Desglose del trabajo en tareas

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU1	Cargar datasets y realizar un análisis exploratorio de los datos	6 h	Alta
HU1	Documentar los hallazgos e identificar una estrategia de balanceo	8 h	Alta
HU2	Graficar la forma de onda temporal de la clases representativas	5 h	Media
HU2	Generar representaciones en frecuencia de cada clase y comparar visualmente	6 h	Media
HU3	Remuestrear todas las grabaciones a una frecuencia de muestreo común	7 h	Alta
HU3	Normalizar la amplitud de cada señal y marcar los segmentos con ruido excesivo	4 h	Alta
HU3	Eliminar ruido excesivo en los segmentos marcados	7 h	Alta
HU4	Implementar pipeline para la extracción de datos	7 h	Alta
HU4	Almacenar los features generados en un formato acorde y documentar lo realizado	6 h	Alta
HU5	Definir y documentar la arquitectura del modelo	5 h	Alta
HU5	Entrenar modelo y ajustar hiperparámetros	4 h	Alta
HU6	Entrenar y ajustar modelos cardíacos y pulmonares por separados	6 h	Alta
HU6	Construir una tabla comparativa y analizar los resultados	5 h	Media
HU7	Calcular accuracy, F1-score por clase, matriz de confusión y curva ROC sobre el conjunto de prueba	4 h	Alta
HU7	Generar visualizaciones de cada métrica.	5 h	Media

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU8	Seleccionar trabajos relevantes de la literatura y extraer métricas principales	6 h	Baja
HU8	Construir una tabla comparativa e identificar el aporte diferencial del trabajo	4 h	Baja
HU9	Redactar el informe final cubriendo todas las etapas del pipeline	8 h	Alta
HU9	Revisar el informe junto al director e incorporar las correcciones antes de la entrega	6 h	Media
HU10	Verificar que el informe cumple los requisitos formales de la especialización	4 h	Media
HU10	Incorporar una sección de conclusiones y trabajo futuro basada en los resultados obtenidos	3 h	Baja

10. Planificación de Sprints